


Bachelorarbeit

Optimierung eines Thermischen Neuronalen Netzwerks zur
Vorhersage von Rotortemperaturen in Permanentmagnet-
Synchronmotoren für den Motorsport

Optimization of a Thermal Neural Network for the Prediction of
Rotor Temperatures in Permanent Magnet Synchronous Motors for
Motor Sports

Samet Kocbay



Betreuer: Univ.-Prof. Dr.-Ing. Tobias Düser
Co-Betreuer: Niklas Frank M. Sc. (KIT)
Lorenz Herber M. Sc. (Compact Dynamics)

Nr.: 4889

Karlsruhe, September 2024

Bachelorarbeit

Herr Samet Kocbay

(Matr.-Nr.: 2283972)

Optimierung eines Thermischen Neuronalen Netzwerks zur Vorher- sage von Rotortemperaturen in Permanentmagnet-Synchronmoto- ren für den Motorsport

Die Bachelorarbeit ist im engen Kontakt mit dem Institut auszuarbeiten.
Eine Einsichtnahme Dritter darf nur nach Rücksprache mit dem Institut
erfolgen.

Ausgabetag: 03.06.2024

Abgabetag: 03.09.2024

Betreuer: Univ.-Prof. Dr.-Ing.-
Tobias Düser

Co-Betreuer: Niklas Frank M. Sc.
Lorenz Herber M. Sc.

(Univ.-Prof. Dr.-Ing. Tobias Düser)

(Niklas Frank M. Sc.)

Bearbeiter:



(Samet Kocbay)

Anschrift:

Ort Viernheim
Straße Wildbannstraße 18
Telefon 0170 3595159

Bachelorarbeit

Aufgabenstellung
für
Herr Samet Kocbay
(Matr.-Nr.:2283972)

Optimierung eines Thermischen Neuronalen Netzwerks zur Vorhersage von Rotortemperaturen in Permanentmagnet-Synchronmotoren für den Motorsport

Die präzise Bestimmung der Rotortemperatur in Permanentmagnet-Synchronmotoren ist von entscheidender Bedeutung für deren effiziente Regelung. Steigende Temperaturen führen zu einer Schwächung des Magnetfeldes, was bei gleichbleibendem Strom eine Reduzierung des abgegebenen Drehmoments zur Folge hat. Diese Drehmomentabweichung beeinträchtigt die Leistungsfähigkeit und Effizienz des Motors, was besonders in anspruchsvollen Anwendungen wie der elektrischen Luftfahrt oder im Motorsport kritisch ist.

Diese Bachelorarbeit konzentriert sich auf die Entwicklung und Implementierung eines Thermal Neural Networks zur Vorhersage der Rotortemperaturen in einem Permanentmagnet-Synchronmotor. Der Prozess umfasst die Erhebung von Trainingsdaten am Prüfstand, die Optimierung des neuronalen Netzwerks sowie die Entwicklung einer Methode, die über die elektromotorische Kraft ebenfalls die Rotortemperatur bestimmen soll, zur Verbesserung der Vorhersagegenauigkeit und Sicherheit. Darüber hinaus wird das Netzwerk auf einem Steuergerät implementiert und im realen Betrieb auf Fehleranfälligkeit und Stabilität untersucht. Ziel ist es, eine zuverlässige und genaue Methode zur Rotortemperaturbestimmung zu entwickeln, die in verschiedenen Anwendungsbereichen eingesetzt werden kann.

Betreuer: Univ.-Prof. Dr.-Ing. Tobias Düser
Co-Betreuer: Niklas Frank M. Sc.
Lorenz Herber M. Sc.

Erklärung

Hiermit versichere ich, die vorliegende Arbeit selbständig und nur mit den im Literaturverzeichnis angegebenen Quellen und Hilfsmitteln angefertigt zu haben.



Karlsruhe, den 03. September 2024

Kurzfassung

Die Rotortemperatur in permanent erregten Synchronmaschinen ist eine kritische Größe für deren Regelung, da steigende Temperaturen zu einem geschwächten Magnetfeld und folglich zu einem reduzierten Drehmoment führen können. Ein vielversprechender Ansatz zur Bestimmung dieser Temperatur ist die Modellierung mittels eines Thermal Neural Networks, das auf einem Recurrent Neural Network basiert.

Diese Arbeit zeigt die praktische Umsetzbarkeit des Thermal Neural Networks für die Bestimmung der Rotortemperatur und beleuchtet dabei potenzielle Herausforderungen. Ein Thermal Neural Network wurde für einen spezifischen Motor trainiert und optimiert, basierend auf Daten, die an einem Back-to-Back-Prüfstand gewonnen wurden. Anschließend wurde die Stabilität des Netzwerks eingehend untersucht. Die Ergebnisse zeigen, dass das Thermal Neural Network sehr genaue Vorhersagen treffen kann, wobei die Wahl eines geeigneten Initialwerts entscheidend ist. Um dieses Problem zu lösen, wurde ein alternativer Ansatz erforscht, bei dem die Temperatur aus der elektromotorischen Kraft abgeleitet wird. Die Ergebnisse legen nahe, dass unter bestimmten Randbedingungen auch hier präzise Temperaturapproximationen möglich sind, die sich zur Initialwertbestimmung oder zur Synchronisation während des Betriebs eignen. Abschließend wurde das Thermal Neural Network erfolgreich auf dem Steuergerät des Motors implementiert.

Das Thermal Neural Network liefert präzise Vorhersagen der Rotortemperatur, muss jedoch in realen Anwendungen validiert werden, um auch verschiedene Umwelteinflüsse, wie die Umgebungstemperatur, angemessen zu berücksichtigen. Aufgrund seiner flexiblen Architektur bietet das Netzwerk zudem vielversprechende Möglichkeiten für die Anwendung in weiteren elektrischen Komponenten und Systemen, was in zukünftigen Arbeiten weiter untersucht werden sollte.

Abstract

The rotor temperature in permanent magnet synchronous motor is a critical variable for their control, as increasing temperatures can lead to a weakened magnetic field and consequently to reduced torque. A promising approach for determining this temperature is using a thermal neural network based on a recurrent neural network.

This work demonstrates the practical feasibility of the thermal neural network for determining rotor temperature and highlights potential challenges. A thermal neural network was trained and optimised for a specific motor based on data obtained on a back-to-back testbench. The stability of the network was then analysed in detail. The results show that the thermal neural network can make very accurate predictions, although the choice of a suitable initial value is crucial. To solve this problem, an alternative approach was explored in which the temperature is derived from the electromotive force. The results suggest that, under certain boundary conditions, precise temperature approximations are also possible here, which are suitable for determining the initial value or for synchronisation during operation. Finally, the thermal neural network was successfully implemented on the motor's control unit.

The thermal neural network provides precise predictions of the rotor temperature, but needs to be validated in real applications in order to adequately take into account various environmental influences, such as the ambient temperature. Due to its flexible architecture, the network also offers promising possibilities for application in other electrical components and systems, which should be investigated in future work.

Inhaltsverzeichnis

1	Einleitung	4
1.1	Zielsetzung	5
1.2	Aufbau der Arbeit	5
2	Grundlagen	6
2.1	Permanentmagnet-Synchronmotoren	6
2.1.1	Aufbau und Funktionsweise	6
2.1.2	Park-Clark-Transformation	7
2.1.3	Drehmomentabweichung	8
2.1.4	Bedeutung der Rotortemperatur	9
2.1.5	Wärmequellen	10
2.1.6	Elektromotorische Kraft	12
2.2	Neuronale Netzwerke	14
2.2.1	Grundbegriffe neuronaler Netzwerke	15
2.2.2	Recurrent Neural Networks	17
2.2.3	Forward Propagation	18
2.2.4	Truncated Backpropagation Through Time	18
2.2.5	Supervised Learning	19
2.2.6	Techniken zur Trainingsoptimierung	19
2.3	Verwendete Software	21
3	Stand der Forschung	22
4	Thermal Neural Network	24
4.1	Aufbau des Thermal Neural Network	24
4.2	Training	26
5	Methode	27
6	Prüfstand und Messeinrichtung	29
6.1	Aufbau	29
6.2	Rotortelemetrie und Messpunkte	31
6.3	Datenerhebung	34
6.4	Bewertung der Messdaten	35
7	Untersuchungen und Optimierung TNN	37
7.1	Optimierung	37
7.1.1	Trainingsdaten	37
7.1.2	Analyse der TBPTT-Segmentlänge	41
7.1.3	Einbindung von Frequenzgrößen	42
7.1.4	Optimierung der Lernrate	43
7.2	Untersuchung der Vorhersage	45
7.2.1	Vorhersage bei exaktem Startwert	45
7.2.2	Vorhersage bei abweichendem Startwert	46
7.2.3	Schlussfolgerung	47

8	EMK Synchronisation	48
8.1	Ansatz	48
8.2	Messung des EMK-Temperatur-Korrelation	49
8.3	Bestimmung der Temperaturgenauigkeit	52
8.4	Möglichkeiten zur EMK-Messung im Fahrbetrieb	54
8.5	Schlussfolgerung	56
9	Implementierung auf das Steuergerät	57
9.1	Möglichkeiten der Implementierung	57
9.2	TNN als Blockschaltbild	58
10	Zusammenfassung und Ausblick	61
10.1	Zusammenfassung der Ergebnisse	61
10.2	Ausblick	62
	Literatur	63

Anmerkung

In dieser Arbeit werden englische Begriffe für spezielle neuronale Netzwerke oder Bezeichnungen im Bezug auf neuronale Netzwerke verwendet, da sie in der Fachliteratur und der Forschungsgemeinschaft üblicher sind. Beispielsweise werden Begriffe wie **bi-as** und **Feed Forward Neural Network** anstelle ihrer deutschen Übersetzungen verwendet.

Abkürzungsverzeichnis

TNN	Thermisches neuronales Netzwerk
WRC	World Rallye Championship
LMDH	Le Mans Daytona Hybrid
RNN	Recurrent neural network
NN	Neuronales Netzwerk
FNN	Feedforward neural network
PMSM	Permanentmagnet-Synchronmotor
FEM	Finite-Elemente-Methode
EMK	Elektromotorische Kraft
EU	Europäische Union
MSE	Mean squared error
TBPTT	Truncated Backpropagation Through Time

1 Einleitung

Die Relevanz von Elektromotoren hat im Kontext der Mobilität signifikant zugenommen, insbesondere vor dem Hintergrund der wachsenden Herausforderungen des Klimawandels und der entsprechenden regulatorischen Maßnahmen, wie dem von der EU beschlossenen Verbot von Fahrzeugen mit CO₂-Emissionen ab dem Jahr 2035 [10]. Diese Entwicklungen haben nicht nur Auswirkungen auf den Automobilsektor, sondern auch auf die regionale Luftfahrt, wo ein deutlicher Trend hin zum elektrischen Fliegen zu erkennen ist. Sowohl im Automobilbereich als auch in der Luftfahrtbranche ist eine hohe Leistungsfähigkeit von Elektromotoren erforderlich, um die benötigten Drehmomente und Drehzahlen präzise bereitzustellen.

Die Rotortemperatur spielt eine entscheidende Rolle bei der Steuerung von Motoren, da sie direkt die Drehmomentgenauigkeit beeinflusst. Ein Anstieg der Rotortemperatur schwächt das Magnetfeld, was bei konstantem Strom zu einer Verringerung des abgegebenen Drehmoments führt. Besonders im Motorsport, wo jede Verbesserung der Rundenzeit um Bruchteile einer Sekunde über Sieg oder Niederlage entscheiden kann, ist es unerlässlich, dass das Drehmoment konstant und zuverlässig bereitgestellt wird. Eine präzisere Überwachung und Regelung der Rotortemperatur ermöglicht es, den Motor optimal auszunutzen, ohne das Risiko eines Ausfalls eingehen zu müssen. So kann die Leistung maximiert und die Zuverlässigkeit erhöht werden, was auf der Rennstrecke einen entscheidenden Vorteil verschafft.

Diese Bachelorarbeit widmet sich dem Training und der Optimierung eines Thermal Neural Networks (TNN) [16], das zur Vorhersage der Rotortemperatur in einem Permanentmagnet-Synchronmotor (PMSM) eingesetzt wird. Darüber hinaus wird eine Methode untersucht, die die Vorhersagestabilität erhöht, indem sie die Rotortemperatur auch aus der elektromotorischen Kraft (EMK) approximiert. Abschließend wird das TNN auf dem Steuergerät implementiert. Die Anwendung des Ansatzes wird am Beispiel eines Motors demonstriert, der von Compact Dynamics entwickelt wurde und in den Fahrzeugen der World Rally Championship (WRC) zum Einsatz kommt.

Das TNN basiert auf einem Recurrent Neural Network (RNN), das sich insbesondere für die Verarbeitung sequenzieller Daten eignet, wie sie in diesem Fall vorliegen. Dabei werden neben den Größen Strom, Drehmoment, Drehzahl, Stator- und Kühlwassertemperatur auch die vorhergesagten Temperaturen aus dem vorherigen Zeitschritt als Eingabegrößen berücksichtigt. Das TNN besteht aus zwei Subnetzwerken, welche die Parameter Verlustleistung und thermische Konduktivität der nach Euler diskretisierten Fouriersche Differentialgleichung der Wärmeleitung abbilden und daraus die Temperatur berechnen [16].

1.1 Zielsetzung

Das Ziel der Arbeit ist die Implementierung eines TNN zur Vorhersage der Rotortemperaturen in einem PMSM zu untersuchen und zu optimieren.

Im Mittelpunkt steht die Untersuchung der Zuverlässigkeit des implementierten neuronalen Netzwerks (NN) sowie die Entwicklung einer Methode, die über eine eigenständige Temperaturberechnung aus der EMK zur Korrektur der Vorhersage genutzt werden soll. Des Weiteren soll das TNN in das Simulink-Modell des Steuergeräts implementiert werden.

Für die Durchführung der Tests wird ein Motor aus dem WRC verwendet. Es ist wichtig zu betonen, dass die entwickelten Methoden und Erkenntnisse nicht speziell für WRC-Motoren entwickelt wurden. Stattdessen soll am Beispiel dieses Motors gezeigt werden, dass die Ansätze allgemein anwendbar sind.

1.2 Aufbau der Arbeit

Nach der Einleitung und Zielsetzung wird in Kapitel 2 die theoretische Grundlage gelegt, wobei zunächst die Funktionsweise von PMSM und neuronalen Netzwerken erläutert wird. In Kapitel 3 wird die Relevanz und Vielfalt der Methoden zur Bestimmung der Rotortemperatur dargestellt. Anschließend wird in Kapitel 4 die Funktionsweise des TNN erklärt.

Das Kapitel 6 beschreibt den Aufbau des Prüfstands sowie die Qualität der erhobenen Daten. In Kapitel 7 erfolgt die Optimierung des TNN, das anhand der erfassten Daten trainiert wird. Danach wird in Kapitel 8 eine weitere Methode vorgestellt, die die Rotortemperatur über die EMK berechnet und als Korrektur zum TNN eingesetzt werden soll. Kapitel 9 behandelt die Implementierung des TNN auf dem Steuergerät des Motors.

Abschließend werden in Kapitel 10 die Ergebnisse der einzelnen Kapitel zusammengefasst und es folgt ein Fazit mit einem Ausblick auf weitere mögliche Aufgaben, die sich aus dieser Arbeit ergeben.

2 Grundlagen

In diesem Kapitel werden die Grundlagen von PMSM und NN, insbesondere RNN, behandelt. Die Funktionsweise der Motoren und die wichtigsten Konzepte der NN werden erläutert.

2.1 Permanentmagnet-Synchronmotoren

2.1.1 Aufbau und Funktionsweise

Die PMSM ist eine elektrische Maschine, die im motorischen Betrieb elektrische Energie in mechanische Energie und umgekehrt im generatorischen Betrieb mechanische Energie in elektrische Energie umwandelt. PMSM werden häufig als Traktionsmaschinen in batterieelektrischen Fahrzeugen eingesetzt, da sie einen vergleichsweise hohen Wirkungsgrad und eine hohe Leistungsdichte aufweisen [29].

Eine PMSM besteht aus einem Stator und einem Rotor, je nach Bauweise kann der Rotor innerhalb oder außerhalb des Stators liegen. Bei dem betrachteten Motor handelt es sich um einen Außenläufer (s. Abb. 1), der Rotor befindet sich also außerhalb des Stators. Der Rotor ist mit Permanentmagneten bestückt und erzeugt somit ein statisches Magnetfeld. Der Stator besteht aus Spulen, die um den Rotor herum angeordnet sind. Diese Spulen werden oft als Wicklungen bezeichnet und sind in der Regel in einem Eisenkern angeordnet, um die magnetische Leitfähigkeit zu erhöhen und Verluste zu verringern.




Abbildung 1: Exemplarischer Aufbau eines Außenläufers [7]

Durch die Verschaltung und die zeitversetzte Einspeisung von Wechselstrom in die Statorwicklungen wird ein magnetisches Drehfeld erzeugt. Die Wechselwirkung zwischen dem rotierenden Magnetfeld des Stators und dem statischen Magnetfeld der Permanentmagnete im Rotor erzeugt die Drehbewegung und damit die mechanische Leistung des Motors [6]. Die Drehung des Magnetfeldes des Stators

entspricht der Drehung des Rotors, daher spricht man von einem Synchronmotor. Durch die Steuerung des Stromflusses in den Statorwicklungen lassen sich damit Drehzahl und Drehmoment des Motors regeln.

2.1.2 Park-Clark-Transformation

Um die beim Training des NN verwendeten Größen I_d , I_q , U_d , U_q zu verstehen, wird im Folgenden kurz auf die Park-Clarke-Transformation eingegangen.

In der mathematischen Modellierung von PMSM werden oft komplexe Wechselstrom- und Raumvektorrechnungen verwendet, um das Verhalten des Motors präzise zu beschreiben. Ein häufig verwendetes Modell basiert auf den Park- und Clarke-Transformationen. Die Clarke-Transformation wandelt die dreiphasigen Statorströme in ein zweidimensionales Koordinatensystem um, das als α - β -Koordinatensystem bezeichnet wird. Dabei wird der Stromvektor in zwei Komponenten aufgeteilt: I_α und I_β (s. Abb. 2). Diese Transformation reduziert die drei Phasenströme auf zwei orthogonale Komponenten (s. Abb. 3) und erleichtert die Analyse des Statorstroms in Bezug auf das stehende Statorkoordinatensystem.

Die Park-Transformation wiederum ermöglicht die Darstellung der elektrischen Größen im rotierenden Koordinatensystem, das mit dem Rotor des Motors synchronisiert ist. Dabei werden die Komponenten des Stroms und der Spannung im statorfesten Koordinatensystem (I_α , I_β) in die Komponenten im rotorfesten Koordinatensystem (I_d , I_q) umgewandelt (s. Abb. 2). Diese Transformation ist entscheidend für die Steuerung und Regelung von PMSM, da sie ermöglicht, die Beziehung zwischen elektrischen Größen und dem rotierenden Magnetfeld des Motors zu analysieren und zu beeinflussen [23].




Abbildung 2: Übersicht eines Spannungszeigers in den verschiedenen Koordinatensystemen [23]




Abbildung 3: Transformierte Größen: Zunächst der dreiphasige Strom der über die Park-Transformation in den zweiten Graph und über die Clark-Transformation in den dritten Graph umgewandelt wird.

Die Park- und Clark-Transformation bieten zwei wesentliche Vorteile im Bezug auf das NN. Erstens reduzieren sie die dreiphasigen Größen auf zwei Komponenten, was die Komplexität des NN verringert, da somit weniger Eingabegrößen notwendig sind. Zweitens wandelt sie die sinusförmigen Signale in Gleichgrößen um (s. Abb. 3), was das Training des NN erleichtert, da konstante Signale einfacher zu verarbeiten sind.

2.1.3 Drehmomentabweichung

Um den Einfluss der Temperatur auf die Drehmomentgenauigkeit abzuschätzen, wird die Drehmomentabweichung im Bezug auf die Statortemperatur dargestellt. Die Drehmomentabweichung bezeichnet die prozentuale Differenz zwischen dem angeforderten und dem tatsächlichen Drehmoment. Es wird davon ausgegangen, dass der Stator sich ähnlich zu dem Rotor erwärmt.




Abbildung 4: Drehmomentabweichung über die Statortemperatur

Während zu Beginn die Abweichung des Drehmoments mit steigender Temperatur nur langsam zunimmt, wird die Abweichung des Drehmoments mit steigender Temperatur immer größer. Die Abnahme des Drehmoments ist eine Folge der Schwächung des Permanentmagnetflusses, welche von der Temperatur abhängt. Da die blaue Kurve bei einer höheren Drehzahl ermittelt wurde, ist die Verlustleistung durch die höhere Drehzahl größer und damit der Temperatureintrag in den Rotor höher, was zu einem schnelleren Anstieg der Drehmomentabweichung führt.

Bei höheren Temperaturen entstehen starke Abweichungen zwischen dem geforderten und abgegebenen Drehmoment, welche besonders im Rennsport zu relevanten Rundenzeitverlusten führen können.

2.1.4 Bedeutung der Rotortemperatur

Die für die Temperatur relevanten Komponenten in der PMSM sind die Statorwicklung und die Permanentmagnete im Rotor. Bei steigenden Statortemperaturen nimmt der elektrische Widerstand im Kupfer zu, wodurch die Stromwärmeverluste steigen. Dies hat einen verringerten Wirkungsgrad zur Folge. Weitere Elemente wie beispielsweise die Lager werden ebenfalls durch die Temperatur in ihrem Verhalten beeinflusst, aber sind nicht Untersuchungsgegenstand dieser Arbeit.

Bezüglich des Rotors sind mehrere temperaturbedingte Effekte von Relevanz. Einer davon ist die Entmagnetisierung der Permanentmagnete. Diese kann infolge unzulässig hoher Temperaturen erfolgen, wobei die Schädigung der Maschine irreversibel ist. Die Entmagnetisierung erfolgt, wenn die Curie-Temperatur der Magnete überschritten wird. In der Praxis ist jedoch vor allem relevant, dass die Magnete durch eine Kombination aus hohen Temperaturen und einem hohen Gegenfeld entmagnetisiert werden können [20].

Zudem nimmt mit steigender Temperatur die Remanenzflussdichte von Permanentmagneten ab. Dies bedeutet, dass bei höheren Temperaturen ein geringerer magnetischer Fluss im Rotor erzeugt wird, so dass zur Aufrechterhaltung des erforderlichen Drehmoments ein höherer Strom erforderlich ist, was zu zusätzlichen Kupferverlusten führt [20].

Des Weiteren kann die Temperatur den Alterungsprozess der Permanentmagnete langfristig beschleunigen. Dies führt zu einer allmählichen Abschwächung ihrer magnetischen Eigenschaften und kann letztendlich die Leistungsfähigkeit des Motors beeinträchtigen. [17]. Da der betrachtete Motor jedoch in der WRC zum Einsatz kommt und lediglich für eine Saison gefahren wird, was 13 Rennen mit einer maximalen Distanz von 350 Kilometern und einer durchschnittlichen Fahrzeit von ungefähr vier Stunden entspricht, kann dieser Aspekt vernachlässigt werden [8].

Eine möglichst genaue und zuverlässige Vorhersage der Rotortemperatur ist von entscheidender Bedeutung, da sie eine höhere Belastung des Systems ohne die Gefahr eines Ausfalls ermöglicht. Zudem kann durch eine stärkere Berücksichtigung der Rotortemperatur in der Regelung eine geringere Drehmomentabweichung erreicht werden.

Eine verbesserte Übereinstimmung zwischen dem vom Fahrer angeforderten Drehmoment und dem tatsächlich an den Rädern übertragenen Drehmoment verbessert die Stabilität und die Kontrolle des Fahrzeugs. Dies ist insbesondere in anspruchsvollen Fahrsituationen von Bedeutung, in denen eine präzise Traktion erforderlich ist, wie beispielsweise auf rutschigen oder unebenen Strecken im Rallyesport. Eine geringere Drehmomentabweichung trägt zudem dazu bei, dass die Leistungsentfaltung des Motors gleichmäßiger ist, was wiederum zu einer konsistenteren Beschleunigung und einem zuverlässigeren Handling des Fahrzeugs führt.

2.1.5 Wärmequellen

Die Temperaturen der verschiedenen Komponenten des Elektromotors während des Betriebs resultieren aus einem Zusammenspiel von Verlusten, Umgebungstemperatur und Kühlleistung. Die Gesamtverlustleistung (1) teilt sich dabei grundlegend in Stromwärme-, Eisen-, Permanentmagnet- und Reibungsverluste auf [20].

$$P_{V,ges} = P_{V,Sw} + P_{V,Fe} + P_{V,PM} + P_{V,Reib} \quad (1)$$

Für die Vorhersage der Temperatur durch das NN ist die Berechnung der Verluste selbst, wie es sonst über eine FEM-Simulation möglich wäre, nicht erforderlich. Stattdessen ist die Identifizierung variabler Größen, welche einen Einfluss auf die Verlustleistung ausüben, von Bedeutung. Mithilfe derer kann die vorliegende Liste an Eingangsgrößen um neue Merkmale erweitern und ein potenziell akkurateres Netzwerk trainieren. Dabei ist es von entscheidender Bedeutung, dass diese Größen entweder im Betrieb messbar sind oder auf Grundlage messbarer Größen in Echtzeit

berechnet werden können, da sie sich sonst nicht für eine Vorhersage im Betrieb eignen.

Im Folgenden werden die Verlustmechanismen beschrieben und die Größen hervorgehoben, die für das TNN relevant sein können. Im Allgemeinen sind alle konstanten Größen für das Training des NN vernachlässigbar. Das Modell würde keine Variation in den Eingaben erkennen und wäre daher nicht in der Lage, Muster zu erkennen. Es wäre jedoch denkbar, dass eine Eingangsgröße für das Modell mit Hilfe einer konstanten Größe berechnet wird und damit relevant wird, wenn sich daraus eine Gewichtung ergibt, die durch die Normierung nicht aufgehoben wird. Der Einfluss der Größen auf die Vorhersagegenauigkeit wird später im Rahmen einer Sensitivitätsanalyse bewertet.

- **STROMWÄRMEVERLUSTE** Die Stromwärmeverluste sind Verluste in den stromdurchflossenen Leitern, welche durch den elektrischen Widerstand der Leiter verursacht werden. Der elektrische Widerstand ist von der Temperatur der Leiter abhängig.

$$P_{V,Sw} = R_{el} I^2 k_I \quad (2)$$

$$R_{el} = R_{el,0} [1 + \alpha_{el} (\theta_L - \theta_0)] \quad (3)$$

Der Temperaturkoeffizient α_{el} in Gleichung (3), der elektrische Widerstand bei Referenztemperatur R_{el} , sowie der Stromverdrängungsfaktor k_I in Gleichung (2) werden als konstant angenommen und sind daher für die Ausgabe unseres NNs irrelevant. Hingegen sind der Strom I und die Änderung der Statortemperatur θ_L als Eingabegrößen relevant.

- **EISENVERLUSTE** Die Eisenverluste setzen sich aus den Hystereseverlusten (5), Wirbelstromverlusten (6) und Zusatzverlusten (7) zusammen. Dieser Verluste sind proportional oder überproportional mit der Frequenz f (4) verknüpft und abhängig von der Flussdichte B [20]

$$f = \frac{n}{p} \quad (4)$$

$$P_{V,Fe,Hy} \propto B^2 f \quad (5)$$

$$P_{V,Fe,Wi} \propto B^2 f^2 \quad (6)$$

$$P_{V,Fe,Zu} \propto B^2 f^{1.5} \quad (7)$$

Die Drehzahl n ist direkt proportional zur Frequenz. Es bedarf daher nur einer der beiden als Eingangsgröße, da die Drehzahl nach der Normierung direkt der normierten Frequenz entspricht [6]. Dagegen können die quadrierte und die mit 1,5 potenzierte Frequenz als zusätzliche Eingangsgrößen in Betracht gezogen werden.

- **PERMANENTMAGNETVERLUSTE** Wirbelstromverluste entstehen, wenn in den leitfähigen Teilen von Permanentmagneten durch ein sich änderndes Magnetfeld Wirbelströme induziert werden. Diese Wirbelströme erzeugen Wärme und führen zu Energieverlusten [20]. Darum stellt die Messung des Magnetflusses eine sinnvolle Eingangsgröße für das NN dar, da der Magnetfluss einerseits mit den Wirbelstromverlusten zusammenhängt und außerdem temperaturabhängig ist. Die Messung des Magnetflusses kann mithilfe verschiedener Messinstrumente geschehen, wie mit einem Gaussmeter oder Hall-Effekt-Sensoren.
- **REIBUNGSVERLUSTE** Die Reibungsverluste setzen sich aus den Lagerreibungsverlusten und den Luftreibungsverlusten zusammen. Luftreibungsverluste treten im Luftspalt zwischen Rotor und Stator, aber auch an der Stirnseite des Rotors auf und sind von der Strömungsgeschwindigkeit und, damit wie auch die Lagerreibungsverluste, von der Drehzahl abhängig [26][19].

Die Größen f^2 , $f^{1.5}$, I^2 und gegebenenfalls der Magnetfluss können als zusätzliche Größen neben I_d , I_q , U_d , U_q , n (Drehzahl), M (Drehmoment), T_c (Temperatur der Kühlflüssigkeit) in Betracht gezogen werden.

Zusammenfassend wird die Rotortemperatur maßgeblich durch die Verluste, die Kühlleistung sowie die Außentemperatur bestimmt. Die Geometrie des Motors spielt ebenfalls eine Rolle, da beispielsweise zwei gleich große Wärmequellen unterschiedlich stark auf die Rotortemperatur Einfluss nehmen können. Dies ist insbesondere der Fall, wenn eine Wärmequelle näher am Rotor ist oder wenn das Material zwischen der Wärmequelle und dem Rotor eine höhere Wärmeleitfähigkeit aufweist.

2.1.6 Elektromotorische Kraft

Die EMK, auch als Induktionsspannung oder Quellspannung u_i bezeichnet, ist die Spannung, die in einem elektrischen Leiter erzeugt wird, wenn dieser sich in einem magnetischen Feld bewegt oder wenn sich das magnetische Feld um den Leiter verändert [27]. Diese Spannung entsteht aufgrund des Induktionsgesetzes von Faraday (8), welches besagt, dass eine zeitliche Änderung des Magnetflusses Φ durch eine Spule eine Spannung in der Spule induziert [6].

$$u_i = -N_c \cdot \frac{d\Phi}{dt} \quad (8)$$

Mit der Flussverkettung Ψ , die sich unter anderem aus dem Integral der magnetischen Flussdichte B über die Fläche ergibt,

$$\Psi = N_c \Phi = N_c \int_A \vec{B} \cdot d\vec{A} \quad (9)$$

setzt sich das Induktionsgesetz in allgemeiner Form zusammen zu:

$$u_i = -\frac{d\Psi}{dt} \quad (10)$$

Bei Null-Drehmoment dreht sich der Rotor eines Motors ohne Last. In diesem Zustand kann die EMK relativ einfach gemessen werden, da keine Belastung durch das Drehmoment die Messung beeinflusst. Die induzierte Spannung (EMK) in den Statorwicklungen ist direkt proportional zur Drehzahl des Rotors [6] und der Stärke des Magnetfelds der Permanentmagnete (9), sowie die Anzahl der Windungen in Serie N_c [6]. Der Vorteil der Messung der EMK bei Null-Drehmoment ist, dass keine zusätzlichen Kräfte oder Ströme im Motor vorhanden sind, die die Messung verfälschen könnten.

Wie bereits in Kapitel 2.1.4 *Bedeutung der Rotortemperatur* erklärt, steht die magnetische Flussdichte der Permanentmagnete in direkter Verbindung mit der Magnet- und somit Rotortemperatur. Dies erlaubt es über die Messung einer EMK auf die Temperatur zu schließen [22]. Die Ermittlung der Rotortemperatur durch eine EMK-Messung ist besonders für Anwendungen von Interesse, bei denen die direkte Temperaturmessung am rotierenden Teil nur schwer möglich ist. Durch Kalibrierung der EMK-Temperatur-Kennlinie kann so eine Überwachung der Rotortemperatur erfolgen, was für die Stabilität des NN von Vorteil sein kann.

2.2 Neuronale Netzwerke

NN sind eine Klasse von maschinellen Lernverfahren. Sie bestehen aus einer Vielzahl von verbundenen Knoten, die als künstliche Neuronen bezeichnet werden. Jedes Neuron nimmt Eingaben entgegen, verarbeitet diese durch eine Aktivierungsfunktion und gibt das Ergebnis an andere Neuronen weiter. Durch das Trainieren auf großen Datenmengen können NN komplexe, nichtlineare Muster erkennen und Vorhersagen oder Entscheidungen treffen.

NN haben in den letzten Jahren enorme Fortschritte in verschiedenen Bereichen der künstlichen Intelligenz erzielt, wie der Bild- und Spracherkennung, der Vorhersage von Zeitreihen oder der automatischen Übersetzung. Ihre Fähigkeit, aus Daten hochkomplexe Muster zu lernen, macht sie zu einem leistungsstarken Werkzeug für viele Anwendungen.

Die Architektur des NN kann je nach Anwendungsfall und Problemstellung variieren. Eine bekannte Variante sind die RNNs, die für die Verarbeitung von sequenziellen Daten wie Texten, Audio oder Zeitreihen eingesetzt werden. RNNs haben eine interne Rückkopplungsschleife, die es ihnen ermöglicht, Informationen aus vorherigen Eingaben zu berücksichtigen und so Kontexte und Abhängigkeiten innerhalb von Sequenzen zu erfassen.

Im Folgenden werden die theoretischen Grundlagen und Konzepte von NN näher erläutert. Dabei wird insbesondere auf RNNs eingegangen, die für diese Arbeit von besonderer Relevanz sind.




Abbildung 5: Beispiel Neuron mit einer Sigmoid-Aktivierungsfunktion [28]

2.2.1 Grundbegriffe neuronaler Netzwerke

- **NEURON** Ein künstliches Neuron, wie in Abbildung 5 dargestellt, ist die grundlegende Recheneinheit in NN. Es nimmt gewichtete Eingaben entgegen, summiert diese mit einem Bias-Wert und berechnet anschließend einen Ausgabewert durch Anwendung einer nichtlinearen Aktivierungsfunktion auf die Summe.
- **EINGABE- UND AUSGABESCHICHT (INPUT- AND OUTPUTLAYER)** Die Eingabeschicht ist die erste Schicht eines NN und repräsentiert die Eingabedaten. Die Ausgabeschicht ist die letzte Schicht und liefert die Vorhersagen oder Ergebnisse des Modells.
- **WEIGHTS** Jede Verbindung zwischen Neuronen hat ein numerisches Gewicht, das angibt, wie stark das Eingangssignal für die Berechnung des Ausgangssignals gezählt wird. Diese Gewichte werden während des Trainings angepasst.
- **BIAS** Der Bias ist ein zusätzlicher Parameter in jedem Neuron, der die Aktivierungsfunktion entlang der X-Achse verschiebt und es dem Neuron ermöglicht, auf Eingaben zu reagieren, die sonst ignoriert werden.
- **OVERFITTING UND UNDERFITTING** Overfitting tritt auf, wenn das Modell die Trainingsdaten zu genau modelliert, aber eine deutlich schlechtere Vorhersage für noch unbekannte Daten erbringt. Underfitting hingegen liegt vor, wenn das Modell weder die Trainings- noch die Testdaten gut modellieren kann.
- **AKTIVIERUNGSFUNKTION** Aktivierungsfunktionen stellen mathematische Operationen dar, welche auf die gewichteten Summen der Eingaben eines Neurons angewendet werden, um dessen Ausgabewert zu berechnen. Sie spielen eine zentrale Rolle in NNs, da sie die Nichtlinearität einführen können, welche es dem Netzwerk ermöglicht, komplexe Muster zu lernen und zu modellieren.

Tanh-Funktion 6 ist eine weit verbreitete Aktivierungsfunktion. Sie transformiert die Eingaben in den Bereich von -1 bis 1 und ist durch die folgende Formel definiert:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (11)$$

Sigmoid-Funktion 6 ist eine weit verbreitete Aktivierungsfunktion. Sie transformiert die Eingaben in den Bereich von 0 bis 1 und ist durch die folgende Formel definiert:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (12)$$




Abbildung 6: Sigmoid- und Tanh-Funktion [30]

Eine weitere häufig verwendete Aktivierungsfunktion ist die ReLU-Funktion (Rectified Linear Unit), sie setzt negative Eingaben auf null und lässt positive Eingaben unverändert.

- **LOSS FUNKTION** Die Loss-Funktion berechnet den Unterschied zwischen den vorhergesagten Werten des Modells und den tatsächlichen Werten aus den Trainingsdaten. Die Wahl der Loss-Funktion hängt von der Art des Problems ab, das gelöst werden soll.

Mean Squared Error (MSE): Wird häufig in Regressionsproblemen verwendet. Sie berechnet den Durchschnitt der quadrierten Differenzen zwischen den vorhergesagten und den tatsächlichen Werten:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (13)$$

Die Loss-Funktion ist entscheidend für das Training eines Modells, da sie dem Optimierungsalgorithmus (z. B. Gradient Descent) eine Richtung vorgibt, in die die Modellparameter angepasst werden sollen, um die Fehlervorhersage zu minimieren und die Modellleistung zu verbessern.

Weitere typische Kostenfunktionen sind der Cross-Entropy-Loss oder der Hinge Loss, diese finden häufig in Klassifikationsproblemen Einsatz.

- **VALIDATION LOSS UND TRAININGS LOSS** Der Validation Loss ist der Fehler, der auf einem separaten Validierungsdatensatz mithilfe der Loss Funktion berechnet wird, um die Leistung eines Modells während des Trainings zu bewerten. Der Trainings Loss hingegen ist der Fehler, der auf den Trainingsdaten selbst berechnet wird und dient zur Anpassung der Modellparameter während des Trainingsprozesses.

2.2.2 Recurrent Neural Networks

RNNs zeichnen sich dadurch aus, dass sie sowohl die aktuellen Eingaben als auch die bisherige Sequenzhistorie für ihre Berechnungen berücksichtigen können. Dies ermöglicht das Modellieren von kontextabhängigen Mustern und langreichweitigen Abhängigkeiten innerhalb von Sequenzdaten. Im Gegensatz zu Feed-Forward-Netzen, die nur die aktuelle Eingabe betrachten, besitzen RNNs ein "Gedächtnis" in Form des internen versteckten Zustands.

Eine Herausforderung ist jedoch, dass die Gradienten während des Trainings über viele Zeitschritte hinweg entweder exponentiell anwachsen ("exploding gradients") oder sehr klein werden ("vanishing gradients"). Das kann zu Instabilität, einer langsamen Konvergenz oder sogar dazu führen, dass bestimmte Muster gar nicht erkannt werden. Aus diesem Grund wurden verbesserte RNN-Architekturen wie LSTMs und GRUs entwickelt. LSTMs besitzen spezielle Gating-Mechanismen, die explizit steuern, welche Informationen im Gedächtnis gespeichert oder vergessen werden. Dadurch können sie Informationen über sehr lange Sequenzen behalten, ohne dass es zu Gradienten-Problemen kommt [28].

Eine weitere Herausforderung besteht darin, dass RNNs für jede Sequenzposition berechnet werden müssen, was insbesondere bei sehr langen Sequenzen sehr rechenaufwendig sein kann. Um die Rechendauer zu begrenzen wurde die Methode Truncated Backpropagation Through Time (TBPTT) entwickelt. Bidirektionale RNNs erweitern das Konzept, indem zusätzliche Verbindungen von der Zukunft in die Gegenwart eingefügt werden, um Kontextinformationen in beide Richtungen auszuwerten. Dies ist besonders für Anwendungen wie Handschrifterkennung nützlich [28].

In der Abbildung 7 ist die Struktur eines RNN zu erkennen. Mit x wird die Eingabe und mit y die Ausgabe zu bestimmten Zeitpunkten beschrieben, während der Hidden State über die Zeitschritte hinweg weitergegeben wird. Der Hidden State stellt genau die Werte dar, welche als rekurrente Größen durchlaufen. Im Prinzip handelt es sich somit um ein gestapeltes Feed Forward Neural Network mit Datenaustausch zwischen den einzelnen Schichten.




Abbildung 7: Schema eines RNN

2.2.3 Forward Propagation

Die Vorwärtspropagierung beschreibt den Prozess, bei dem ein Eingabedatenpunkt durch das NN hindurch propagiert wird, um eine Ausgabe oder Vorhersage zu erhalten. Sie beginnt an der Eingabeschicht, wo die Eingabedaten wie Bilddaten oder eine Texteingabe präsentiert werden. Jedes Neuron in der Eingabeschicht sendet dann ein gewichtetes Signal an die nächste versteckte Schicht. Dort werden diese gewichteten Summen mit einer nichtlinearen Aktivierungsfunktion wie der ReLu- oder Sigmoid-Funktion bearbeitet.

Dieser Vorgang wiederholt sich Schicht für Schicht, wobei jedes Neuron der vorherigen Schicht mit jedem Neuron der nächsten Schicht verbunden ist und seine gewichteten Signale weitergibt. In den tieferen Schichten extrahieren die Neuronen zunehmend abstrakte und komplexe Merkmale aus den Eingabedaten. Schließlich erreichen die propagierten Signale die Ausgabeschicht, wo die Vorhersage oder Entscheidung des NNs basierend auf den finalen gewichteten Summen getroffen wird.

Die Vorwärtspropagierung ist der erste Teil der Berechnung in einem NN. Ihr schließt sich während des Trainings die Rückwärtspropagierung an, bei der die Gewichte basierend auf den Fehlern zwischen Vorhersage und Zielvorgabe optimiert werden.

2.2.4 Truncated Backpropagation Through Time

TBPTT ist eine Technik, die speziell für das Trainieren rekurrenter NN auf Sequenzdaten entwickelt wurde. Der Kerngedanke ist die Berechnungen der Rückwärtspropagation der Gradienten durch "Abschneiden" der Backpropagation nach einer bestimmten Anzahl von Zeitschritten zu beschränken.

Der Grund hierfür ist, dass bei RNNs die Fehler in der Regel über die gesamte Sequenz zurückpropagiert werden müssen. Bei sehr langen Sequenzen kann dies

zu numerischen Instabilitäten und dem bereits erwähnten Problem der verschwindenden oder explodierenden Gradienten führen. Mit TBPTT wird die Sequenz in mehrere kürzere Segmente unterteilt. Die Vorwärtspropagation läuft weiterhin über die gesamte Sequenz, aber die Fehlerrückwärtspropagation erfolgt jeweils nur für ein kurzes Segment. Am Ende eines Segments wird der versteckte Zustand als Startwert für das nächste Segment genutzt [13].

Die Länge dieser Segmente, also die Anzahl der Zeitschritte für TBPTT, ist ein Hyperparameter, der optimiert werden muss. Eine kürzere Segmentlänge reduziert den Rechenaufwand, kann aber zu einer schlechteren Modellierung von langwierigen Abhängigkeiten führen. TBPTT ermöglicht eine effizientere und stabilere Optimierung im Vergleich zur vollständigen Backpropagation über eine sehr lange Sequenz. Allerdings stellt es trotzdem nur eine Näherungslösung dar, da langreichweitige Zusammenhänge abgeschnitten werden können [13].

Insgesamt ist TBPTT eine wichtige Technik, um das Training RNN auf langen Sequenzen praktisch handhabbar und numerisch stabiler zu machen.

2.2.5 Supervised Learning

Supervised Learning [24] ist eine grundlegende Methode im Bereich des maschinellen Lernens, bei der ein Modell auf der Grundlage eines gekennzeichneten Datensatzes trainiert wird. Bei diesem Ansatz erhält das Modell zu jedem Trainingsbeispiel sowohl die Eingabedaten als auch die entsprechenden Zielwerte oder Labels.

Der Trainingsprozess zielt darauf ab, eine Funktion zu lernen, die Eingabedaten auf die richtigen Zielwerte abbildet. Dies geschieht, indem das Modell die Fehler zwischen den vorhergesagten und den tatsächlichen Zielwerten minimiert. Typische Algorithmen für überwachtes Lernen sind lineare Regression, Entscheidungsbäume und neuronale Netze.

Im Supervised Learning werden die Daten in der Regel in Trainings- und Testdaten unterteilt. Das Modell wird auf den Trainingsdaten trainiert und auf den Testdaten evaluiert, um seine Fähigkeit zur Generalisierung auf neue, ungesehene Daten zu überprüfen. Dieses Lernparadigma ist besonders nützlich für Aufgaben wie Klassifikation, bei der das Ziel darin besteht, Daten in Kategorien einzuteilen, und Regression, bei der es darum geht, kontinuierliche Werte vorherzusagen.

2.2.6 Techniken zur Trainingsoptimierung

Im Folgenden werden weitere Methoden erklärt, um das Training des NNs zu optimieren, welche für das Training des TNN in dieser Arbeit genutzt werden.

- **EARLY STOPPING** Die Methode des Early Stopping basiert auf der Beobachtung des Gradienten des Validation-Loss über die Epochen. Wenn der Validation-

Loss über eine bestimmte Menge an vergangenen Epochen stagniert oder ansteigt, wird das Training abgebrochen. Diese Methode zielt darauf ab, Overfitting zu verhindern und gleichzeitig Ressourcen zu schonen, indem nicht jedes Setup bis zur maximalen Epochenzahl trainiert wird. Um durch anfängliche Schwankungen des Validation-Losses nicht gleich das Training abzubrechen, wird ein Parameter (Patience) definiert, der eine minimale Anzahl an Epochen festlegt, bevor eine vorzeitige Unterbrechung durchgeführt werden darf.

- **NORMALISIERUNG** Die Normalisierung ist ein Vorverarbeitungsschritt für die Eingabegrößen von NNs. Dabei werden die Eingabegrößen so transformiert, dass sie einen gemeinsamen Wertebereich aufweisen, üblicherweise zwischen 0 und 1 oder -1 und 1. Dies bringt mehrere Vorteile mit sich. Zunächst werden durch die Normalisierung Eingabegrößen mit unterschiedlichen Skalenbereichen und Einheiten gleichmäßig gewichtet, so dass keine aufgrund ihrer größeren Zahlenwerte das Training dominieren. Darüber hinaus verbessert die Normalisierung die numerische Stabilität und Konvergenzgeschwindigkeit während des Trainings des NN. Viele der gängigen Aktivierungsfunktionen in den Neuronen, wie beispielsweise die Sigmoidfunktion, arbeiten zudem besser mit normierten Eingaben in einem bestimmten Bereich [\[30\]](#).
- **MASK TENSOR** Ein Maskentensor besteht aus einer Matrix mit binären Werten, wobei jede Position in der Matrix einem bestimmten Element in einem Datensatz entspricht. Eine binäre Eins (1) in der Maske kann beispielsweise angeben, dass das entsprechende Element im Datensatz berücksichtigt werden soll, während eine Null (0) bedeutet, dass das Element ignoriert werden soll. Die Verwendung eines Maskentensors ermöglicht es flexibel mit Daten umzugehen, die unterschiedliche Längen oder Eigenschaften aufweisen, ohne dass dies das Training oder die Vorhersagen des NN beeinträchtigt.

2.3 Verwendete Software

Zur Fertigstellung der verschiedenen Abschnitte der Arbeit wurden folgende Programme verwendet: Für die Erstellung und das Training des TNN wurde Python benutzt und folgende Packages verwendet: PyTorch [3], NumPy [1], Pandas [2] und SciPy [4].

Für die Implementierung des NN auf dem Steuergerät wird der Forward Pass des TNN zunächst in Simulink 2017a [18] aufgebaut, dann ein C-Code generiert und anschließend über Arctic Studio in ein hex-Code übersetzt. Der Datenaustausch am Prüfstand findet über CANape statt.

- **PYTORCH** PyTorch ist ein Open-Source-Framework, das dynamische Berechnungsgraphen für das Training von NN bietet.
- **NUMPY** NumPy ist eine leistungsstarke Python-Bibliothek für numerische Berechnungen, die es ermöglicht, effizient mit großen mehrdimensionalen Arrays und Matrizen zu arbeiten und umfangreiche mathematische Funktionen zur Verfügung stellt.
- **PANDAS** Pandas ist eine leistungsstarke Open-Source-Bibliothek in Python, die für Datenanalyse und -manipulation verwendet wird. Sie bietet Datenstrukturen und -operationen, mit denen Daten leicht importiert, bereinigt, transformiert und analysiert werden können.
- **SCIPI** SciPy ist eine Open-Source-Bibliothek, die auf NumPy aufbaut und zusätzliche Funktionalitäten für wissenschaftliche und technische Berechnungen in Python bereitstellt, einschließlich Optimierung, Integration, Interpolation, Signalverarbeitung, Bildverarbeitung und vieles mehr.
- **NUMPY** Simulink 2017a ist eine Version der Simulations- und Modellierungsumgebung von MathWorks, die es Ingenieuren und Wissenschaftlern ermöglicht, komplexe dynamische Systeme visuell zu entwerfen, zu simulieren und zu analysieren, indem sie Blockdiagramme verwenden, um die Interaktionen zwischen verschiedenen Komponenten zu modellieren.
- **CANAPE** CANape ist eine Mess-, Kalibrierungs- und Diagnose-Tool von Vector Informatik, das hauptsächlich in der Fahrzeugentwicklung verwendet wird. Es ermöglicht Steuergeräte in Echtzeit zu überwachen, Messdaten aufzuzeichnen, Parameter zu kalibrieren und Diagnosefunktionen durchzuführen, um die Leistung und Zuverlässigkeit von Fahrzeugsystemen zu verbessern.

3 Stand der Forschung

Die Bestimmung der Rotortemperatur in Elektromotoren, insbesondere bei PMSM, stellt eine wichtige Herausforderung dar. In diesem Kapitel werden gängige Methoden zur Bestimmung dieser Temperaturen erläutert.

Eine Methode ist die direkte Temperaturmessung am Rotor. Diese erfolgt hauptsächlich auf zwei Arten: kontaktbasiert oder kontaktlos.

Bei kontaktbasierten Messungen kommen häufig Thermoelemente zum Einsatz. Diese Methode zeichnet sich durch hohe Genauigkeit aus und ermöglicht die Messung der axialen und radialen Temperaturverteilung. Allerdings erfordert sie eine sorgfältige Berücksichtigung in der Rotorkonstruktion, da sich das Messinstrument mit dem Rotor mitbewegen muss. Dies kann die Komplexität und den Aufwand der Messung erhöhen [9].

Im Gegensatz dazu stehen kontaktlose Messverfahren, bei denen häufig Infrarotsensoren verwendet werden. Diese Technik bietet den Vorteil einer einfacheren Implementation, da keine Datenübertragung von rotierenden Teilen erforderlich ist. Zudem hat die kontaktlose Messung meist einen geringeren Einfluss auf den Betrieb des Motors selbst. Allerdings ist diese Methode meist nur für große Maschinen bei geringen Drehzahlen geeignet und liefert oft nur eine durchschnittliche Temperatur, nicht die detaillierte Temperaturverteilung [9].

Neben diesen direkten Messverfahren existieren indirekte Methoden, die physikalische Zusammenhänge ausnutzen. Eine wichtige Technik ist die Back-EMF-Methode (Gegen-EMK), die die Temperaturabhängigkeit des Magnetflusses nutzt, um Rückschlüsse auf die Rotortemperatur zu ziehen [22]. Diese Methode ist besonders vorteilhaft, da sie keine zusätzliche Sensorik erfordert und während des normalen Motorbetriebs angewendet werden kann.

Eine weitere Gruppe von Methoden basiert auf thermischen Modellen. Hierzu gehören Lumped-Parameter-Modelle, die den Motor in thermische Knoten unterteilen und deren Wärmeflüsse berechnen [25]. Diese Modelle bieten einen guten Kompromiss zwischen Genauigkeit und Rechenaufwand. Für detailliertere Analysen kommen Finite-Elemente-Methoden (FEM) zum Einsatz [15]. FEM-Simulationen ermöglichen eine präzise Berechnung der Temperaturverteilung, sind jedoch rechenintensiv und erfordern genaue Kenntnis der Materialeigenschaften und Geometrien.

In jüngster Zeit gewinnen Ansätze des maschinellen Lernens in allen Bereichen an Bedeutung, so auch um die Rotortemperatur basierend auf Betriebsparametern wie elektrischer Leistung, Drehzahl und Kühlwassertemperatur vorherzusagen. Dabei werden auch Ansätze wie das Lumped-Parameter-Modell mit einem Machine Learning Ansatz kombiniert [16] [14], wie auch in dieser Arbeit. Diese Methoden können nach ausreichendem Training sehr genaue Ergebnisse liefern und sind in der Lage komplexe nichtlineare Zusammenhänge zu erfassen.

Jede der vorgestellten Methoden zur Rotortemperaturbestimmung hat ihre spezifischen Vor- und Nachteile, die je nach Anwendungsfall sorgfältig abgewogen werden müssen. Die Wahl des geeigneten Ansatzes hängt von den konkreten Anforderungen ab, wie zum Beispiel der erforderlichen Genauigkeit, dem verfügbaren Bauraum für Sensoren, der Rechenleistung und den Kosten. Die Vielfalt und kontinuierliche Weiterentwicklung dieser Methoden verdeutlichen die zentrale Bedeutung der Rotortemperatur für den Betrieb, die Effizienz und die Lebensdauer von Elektromotoren.

In der Praxis werden oft Kombinationen verschiedener Ansätze eingesetzt, um deren jeweilige Vorteile zu nutzen und Nachteile auszugleichen. Dieses anhaltende Bestreben, die Genauigkeit und Zuverlässigkeit der Temperaturüberwachung zu verbessern, unterstreicht die kritische Rolle der Rotortemperatur für die Leistungsfähigkeit und Langlebigkeit moderner Elektromotoren.

4 Thermal Neural Network

In diesem Kapitel wird die Struktur und Funktionsweise des TNN [16] beschrieben. Im Rahmen einer Optimierung werden weitere Methoden implementiert, um eine verbesserte Vorhersage auf dem ebenfalls in dieser Arbeit erhobenen Rotortemperaturdatensatz zu erreichen.

4.1 Aufbau des Thermal Neural Network

Das TNN ist ein spezialisiertes NN, das entwickelt wurde, um thermische Prozesse in komplexen Systemen zu modellieren. Es basiert auf dem Lumped-Parameter-Thermal-Network (LPTN), das die Wärmeübertragung und -speicherung in einem Netzwerk von verbundenen Knoten beschreibt. Das TNN verwendet NN, um die Wärmeleitfähigkeiten zwischen den Knoten sowie die thermischen Kapazitäten und Leistungsverluste zu lernen und somit die Parameter der LPTN-Gleichung zu approximieren [16].

Die zentrale Komponente des TNN ist die TNNCell, welche die Euler-Diskretisierung der gewöhnlichen Differentialgleichungen umsetzt, die im LPTN verwendet werden. Innerhalb dieser Klasse werden verschiedene Subnetze initialisiert, die jeweils unterschiedliche Komponenten der Differentialgleichung repräsentieren:

- **WÄRMELEITFÄHIGKEITS-SUBNETZ** Dieses Subnetz besteht aus einer linearen Schicht, gefolgt von einer Sigmoid-Aktivierung. Es modelliert die Wärmeleitfähigkeiten zwischen allen Temperaturknoten im Netzwerk. Die Ausgabe dieses Subnetzes wird durch eine Adjazenzmatrix indiziert, um die richtigen Wärmeleitfähigkeiten zwischen verbundenen Knoten auszuwählen. Die Ausgabe beschreibt damit den Einfluss aller im Training berücksichtigten Temperaturen aufeinander.
- **LEISTUNGSVERLUST-SUBNETZ:** Dieses Subnetz besteht aus zwei linearen Schichten, getrennt durch eine Tanh-Aktivierung. Es modelliert die Leistungsverluste in jedem Temperaturknoten. Daher ist es auch relevant die Größen zu identifizieren, welche einen Beitrag zur Verlustleistung haben um diese ebenfalls im Training zu berücksichtigen.
- **THERMISCHE KAPAZITÄTEN:** Die thermischen Kapazitäten der einzelnen Knoten werden ebenfalls als lernbare Parameter dargestellt.

Die Forward-Funktion der TNNCell berechnet in jedem Zeitschritt die Temperaturänderungen zwischen den verbundenen Knoten, wobei die gelernten Wärmeleitfähigkeiten, thermischen Kapazitäten und Leistungsverluste berücksichtigt werden. Die Ausgabe ist die aktualisierte Temperatur im nächsten Zeitschritt.

In der folgenden Abbildung 8 wird der Aufbau des TNN nochmal visuell dargestellt, als Beispiel wird eine LPTN-Struktur dritter Ordnung mit einer zusätzlichen Wärmequelle genutzt. Das TNN verwendet sämtliche Eingangsmerkmale des aktuellen Zeitschritts $\phi[k]$, um die Temperaturen des nachfolgenden Zeitschritts $\theta[k + 1]$ vorherzusagen. Diese Prognose dient als Zellinformation innerhalb des TNN, um die drei Funktionsapproximatoren γ , κ und π weiter zu optimieren.




Abbildung 8: Schematischer Aufbau des TNN [16]

Als Differentialgleichung wird eine Wärmeleitungsgleichung [14] mit einer Wärmequelle p verwendet. Dabei stellt ρ die Dichte, c_p die spezifische Wärmekapazität bei konstanter Temperatur, θ die Temperatur, p eine Wärmequelle aus beispielsweise Verlusten, ∇ den Nabla Operator und λ die thermische Konduktivität dar [16].

$$\rho c_p \frac{\partial \theta}{\partial t} = p + \nabla \cdot (\lambda \nabla \theta) \quad (14)$$

Das TNN wird durch Supervised Learning auf Trainingsdaten thermischer Prozesse trainiert. Supervised Learning, auch überwachtes Lernen genannt, ist ein Ansatz des maschinellen Lernens, bei dem dem Modell Eingabedaten zusammen

mit den gewünschten Ausgabedaten präsentiert werden. Während des Trainings lernen die Subnetze und die thermischen Kapazitäten, die Wärmeübertragung und -speicherung im System so gut wie möglich zu approximieren, indem die Vorhersagen des Modells mit den tatsächlichen Zielwerten verglichen und die Modellparameter iterativ angepasst werden, um die Abweichung zwischen Vorhersage und Ziel zu minimieren. Dadurch kann das trainierte TNN verwendet werden, um die Temperaturentwicklung in ähnlichen thermischen Systemen vorherzusagen oder zu simulieren, indem es neue Eingabedaten verarbeitet und die entsprechenden Temperaturverläufe als Ausgabe liefert.

Eine besondere Stärke des TNN ist seine Fähigkeit, die komplexe nichtlineare LPTN Ordinary-Differential-Equation (ODE) zu approximieren, ohne dass die exakten Modellparameter wie Wärmeleitfähigkeiten und Kapazitäten explizit vorgegeben werden müssen. Stattdessen lernt das Netzwerk diese Parameter implizit aus den Trainingsdaten. Darüber hinaus kann das TNN auf verschiedene Arten thermischer Systeme angewendet werden, indem die Anzahl der Temperaturknoten und die Architektur der Subnetze an die jeweilige Problemstellung angepasst wird.

Insgesamt stellt das TNN einen vielversprechenden Ansatz zur datengesteuerten Modellierung thermischer Prozesse dar, der die Flexibilität NN mit den physikalischen Prinzipien der Wärmeübertragung und -speicherung, beschrieben durch die Differentialgleichung, kombiniert.

4.2 Training

Innerhalb des Trainings des NNs wird die mittlere quadratische Fehlerfunktion (Mean Squared Error, MSE) als Loss-Funktion verwendet. Zusätzlich verwendet das Training die TBPTT Methode. Außerdem wird ein Mask Tensor verwendet, damit die unterschiedlichen Längen der Fahrprofile aus dem Trainingsdatensatz berücksichtigt werden können.

Die zentralen Hyperparameter für das Training sind die Anzahl der Epochen, die Segmentgröße für die TBPTT, sowie die Lernrate des Optimierers. Zusätzlich beinhaltet der Code eine Anpassung der Lernrate nach 75 Epochen. Diese Parameter und weitere Methoden werden innerhalb dieser Arbeit eingeführt um eine Verbesserung der Vorhersage zu erreichen.

Der Trainingsaufbau gliedert sich wie folgt: Zunächst werden die Trainingsdaten in Batches der TBPTT-Länge aufgeteilt. Anschließend folgt eine äußere Schleife über die Epochen und eine innere Schleife über die Batches. In jedem Batch wird das Modell mit den Eingabedaten und dem vorherigen versteckten Zustand aufgerufen, um die Ausgabe und den neuen versteckten Zustand zu berechnen. Der Verlust zwischen Modellausgabe und Zieldaten wird unter Berücksichtigung der Sample Weights bestimmt und für die Rückwärtspropagierung verwendet, wobei der Optimizer die Modellparameter aktualisiert.

5 Methode

Das gezeigte Diagramm (s. Abb. 9) stellt den systematischen Ablauf der Arbeitsschritte dar, um die Temperatur eines Rotors in einem Elektromotor über ein TNN zu bestimmen und anschließend in die Regelung einzubinden. Die orangenen unterlegten Felder zeigen Schritte, die mithilfe von realen Versuchen umgesetzt werden müssen. Dieser Ablauf wurde im Rahmen dieser Bachelorarbeit entwickelt und aufgestellt.




Abbildung 9: Schematischer Ablauf der Arbeitsschritte um die Temperaturgröße in der Regelung des WRC-Motors durch ein TNN zu bestimmen

Zunächst erfolgt die Definition der relevanten Eingangsdaten und Zielgrößen, die das NN lernen soll. Hierzu gehören im vorliegenden Fall die Rotortemperatur sowie weitere Größen wie Drehzahl und Kühlwassertemperatur. Anschließend werden die benötigten Trainings- und Testdatensätze im Kapitel 6.3 *Datenerhebung* generiert. Dies kann über reale Messdaten aus verschiedenen Betriebszuständen sowie ergänzende numerische Simulationen erfolgen. In diesem Fall wurden Messdaten durch Messungen am Prüfstand mittels Rotortelemetrie erzeugt.

In einem ersten Schritt werden die Rohdaten mit Hilfe geeigneter Bibliotheken wie Pandas aufbereitet und für das Training vorbereitet. Das eigentliche Training und die Optimierung des NNs erfolgt dann mithilfe von Machine-Learning-Frameworks wie PyTorch oder TensorFlow [5]. Dies findet im Kapitel 7 *Untersuchung und Optimierung TNN* statt.

Anschließend gilt es, die erreichte Vorhersagegenauigkeit des RNNs zu testen, um festzustellen, ob es den Anforderungen der Regelung gerecht wird. Dabei wird auch die Fehleranfälligkeit bewertet, da bei RNNs die Gefahr besteht, dass sich durch schlechte Vorhersagen in vorherigen Schritten die Abweichungen weiter verstärken. Daher muss die Stabilität der Vorhersage sorgfältig evaluiert werden. Um zusätzliche Sicherheit zu schaffen oder die Vorhersage zu verbessern, können Techniken eingebunden werden, um eine Korrektur der Temperaturvorhersage zu erreichen oder unrealistische starke Anstiege oder Abfälle der Temperatur zu vermeiden.

Dazu wird im Rahmen dieser Arbeit versucht die Korrelation zwischen der EMK und der Magnettemperatur auszunutzen. Das Vorgehen hierzu wird im Kapitel 8 *EMK Synchronisation* beschrieben.

Nach erfolgreichem Training wird das NN schließlich in Kapitel 9 *Implementierung auf das Steuergerät* für den Einsatz auf dem Steuergerät implementiert. Dies kann mithilfe von Entwicklungsumgebungen wie MATLAB/Simulink erfolgen. Der letzte kritische Schritt ist die umfassende Validierung des Gesamtsystems sowohl auf dem Prüfstand als auch unter realen Bedingungen. Nur durch sorgfältige Tests lässt sich sicherstellen, dass die Regelung ihr Potenzial ausschöpft und zuverlässig arbeitet.

6 Prüfstand und Messeinrichtung

In diesem Kapitel erfolgt eine Darstellung des Prüfstands sowie des verwendeten Messinstruments, das für die Generierung der erforderlichen Daten eingesetzt wird. Darüber hinaus wird die Datengenerierung selbst erklärt und die Qualität der Messungen bewertet.

6.1 Aufbau

Der Prüfstand (s. Abb. 10) ist nach dem Back-to-Back Verfahren [12] aufgebaut. Dabei werden die zwei, bis auf die verbauten Temperaturmessinstrumente identischen WRC Motoren über ihre Wellen mechanisch miteinander verbunden und gegenläufig betrieben. Der erste Motor fungiert als Antrieb und wird von einer elektrischen Quelle versorgt.

Der zweite Motor läuft als Lastmaschine und wandelt die mechanische Energie in elektrische Energie um, welche wieder in das System rückgespeist wird. Durch diese Konfiguration kann der zu prüfende Motor unter definierten und variablen Lastbedingungen betrieben werden, ohne dass eine separate mechanische Belastungsquelle erforderlich ist. Beide Motoren sitzen auf der gleichen Spannungsversorgung.

Back-to-Back-Prüfstände ermöglichen detaillierte Messungen und Analysen des Motorverhaltens wie Drehmoment, Drehzahl und Wirkungsgrad. Sie ermöglichen eine genaue Nachbildung realer Betriebsbedingungen und werden sowohl für Entwicklungszwecke als auch für Qualitätsprüfungen in der Elektromotorenfertigung eingesetzt [12].




Abbildung 10: Prüfstand in Back-to-Back Anordnung mit angebunden Messinstrumenten und Stromversorgung




Abbildung 11: Nahaufnahme des Motors mit integrierter Rotortelemetrie

Im Vordergrund von Abbildung 11 mit Rot umrandet ist ein zylindrischer Berstschutz zu sehen, der mit fünf Schrauben befestigt ist. Durch eine Bohrung, in grün markiert, in diesem Berstschutz ist das Messinstrument sichtbar. Diese Konstruktion ermöglicht es, das Messinstrument ein- und auszuschalten. Nach Entfernen des Berstschutzes kann zudem der Akku des Instruments geladen werden.

6.2 Rotortelemetrie und Messpunkte

Um die Temperatur des Rotors zu messen ist eine Messeinrichtung notwendig, die sich mit dem Rotor bewegt. Um das gewährleisten zu können, wurde eine Rotortelemetrie verbaut. Diese sitzt mit auf der Motorwelle und wird mit einer Batterie betrieben. Insgesamt besitzt die Messeinheit vier Anschlüsse für Temperatursensoren. Die gemessenen Temperaturen werden über CAN an den Prüfstandscomputer (XPC) übertragen und können dort über CANape ausgelesen werden. Die wichtigsten Eigenschaften aus dem Datenblatt werden im Folgenden genannt:

- Messeingänge: Vier Thermoelementeingänge
- Messbereich: $-50^{\circ}\text{C} \dots 1310^{\circ}\text{C}$ (Typ K)
- Auflösung: $0,04^{\circ}\text{C}$
- Genauigkeit: max. $\pm (< 0,15 \% \text{ vom Messwert} + 1,2^{\circ}\text{C})$
- Abtastrate: max 40Hz
- Anstiegsgeschwindigkeit: 80000 K/s

Um die Wärmeleitfähigkeit an den Messspitzen der Thermoelemente zu gewährleisten, wurde Loctite EA 9497 verwendet [11]. Dieser Klebstoff zeichnet sich durch seine Wärmeleitfähigkeit und hohe Festigkeit aus, was ihn ideal für die zuverlässige Befestigung der Thermoelemente an den spezifischen Messpunkten macht. Die vier Thermoelemente sind wie auf der Abbildung 12 sichtbar in Bohrungen am Rotor mithilfe eines Klebstoffes angebracht. Die inneren Bohrungen werden in den Abbildungen 13, 14 und 15 dargestellt. Die äußere Bohrung ist schwer einsehbar, aber die Position der Bohrung für die Messspitze lässt sich in Abbildung 16 erkennen. Es kann von einer homogenen Aufheizung des Rotors ausgegangen werden.




Abbildung 12: Schematische Schnittansicht der Messpunkte im Rotor. Zu sehen ist der Rotor rechts geschnitten normal zur Rotationsachse des Motors und links senkrecht dazu.



Abbildung 13: Rotor mit eingeschliffener Nut für die Messspitze auf der Innenseite der Magnete in rot umrahmt



Abbildung 14: Nahaufnahme der Nut



Abbildung 15: Eingeklebtes Thermoelement mit gelb-grüner Verkablung




Abbildung 16: Blick auf den Rotor von der anderen Seite: Die hellblauen Pfeile am Rand zeigen die Position der Bohrung für die Messposition am Außendurchmesser der Magnete an

6.3 Datenerhebung

Für ein erfolgreiches Training des NNs sind Messdaten aus realen Fahreinsätzen von entscheidender Bedeutung. Da die WRC-Motoren jedoch nicht mit einer Rotortelemetrie ausgestattet sind, müssen die benötigten Daten auf andere Weise gewonnen werden. In diesem Fall werden sie am Back-to-Back-Prüfstand erhoben, indem aufgezeichnete Fahrdaten von verschiedenen Rennen auf dem Prüfstand nachgestellt werden.

Durch diese Vorgehensweise kann das Verhalten der Rotortemperatur die gleiche Dynamik aufweisen, die auch in einem realen Rennen auftreten würde. Allerdings hat diese Methode den Nachteil, dass die Umgebungstemperaturen nicht berücksichtigt werden können. Gerade in der WRC finden Rennen unter extremen Temperaturbedingungen statt, die von -30°C bis $+42^{\circ}\text{C}$ reichen können [21]. Dadurch wird insbesondere das Abkühlverhalten beeinflusst. Allerdings werden am Prüfstand und im Renneinsatz die Kühlwassertemperaturen erfasst, die wiederum mit den Umgebungstemperaturen korrelieren. Diese Daten könnten genutzt werden, um Rückschlüsse auf die Auswirkungen unterschiedlicher Umgebungstemperaturen zu ziehen.

Insgesamt sollte die Rotortemperatur im eingelaufenen Zustand nicht zu weit von der Temperatur im Renneinsatz abweichen, allerdings besteht nicht die Möglichkeit die Temperatur des Prüfstandraums oder mit der im WRC Fahrzeug verbauten Kühlungen zu messen.

Eine Möglichkeit, dieses Problem in Zukunft zu umgehen, wäre die Simulation von Messdaten unter Berücksichtigung verschiedener Umgebungstemperaturen. Dadurch ließe sich das NN auf ein breiteres Spektrum an Einsatzbedingungen trainieren. Aktuell besteht jedoch nicht die Möglichkeit, solche simulierten Daten zu generieren.

Letztendlich sollte die tatsächliche Vorhersagegenauigkeit des trainierten NN perspektivisch in realen Fahreinsätzen unter verschiedenen Umgebungsbedingungen getestet und validiert werden. Nur so lässt sich sicherstellen, dass das System den Anforderungen der Praxis gerecht wird.

6.4 Bewertung der Messdaten

Die vier Thermoelemente, von denen jeweils zwei am Innen- und Außenradius des Rotors angebracht sind, liefern im Stillstand und nach längerer Inaktivität des Motors identische Messwerte. Dies bestätigt zunächst die Genauigkeit der Sensoren und der Messung im Ruhezustand. Sobald jedoch das Fahrprofil durchlaufen wird, zeigen Sensor 2 und Sensor 4 negative und schwankende Werte (s. Abb. 17). Diese beiden Messpunkte befinden sich, wie in Abbildung 15 dargestellt, direkt am Luftspalt.




Abbildung 17: Temperaturmessung der vier Thermoelemente während eines simulierten Fahrzyklus

Grund für diese Messabweichungen könnten elektromagnetische Interferenzen und induzierte Spannungen sein, hervorgerufen durch die starken Magnetfelder und die Rotation des Motors. Zusätzlich könnten elektrische Wirbelströme lokale Temperaturgradienten erzeugen, welche die Messgenauigkeit beeinträchtigen. Es ist anzunehmen, dass sich diese Effekte mit steigendem Drehmoment verstärken. Zudem sind die beiden Sensoren im Vergleich zu den Sensoren 1 und 3 nicht verdrillt, weshalb sie anfälliger für elektromagnetische Interferenzen sind. Dies gilt es bei zukünftigen Messaufbauten zu berücksichtigen.

Angeichts dieser Einflussfaktoren werden für das Training des NNs ausschließlich die Messwerte der beiden Sensoren herangezogen, die sich nicht in unmittelbarer Nähe des Luftspalts befinden und zuverlässige Messungen liefern. Für künftige Messreihen empfiehlt sich eine sorgfältige Planung der Sensorplatzierung unter Berücksichtigung dieser Erkenntnisse, um die Präzision und Zuverlässigkeit der Temperaturerfassung zu optimieren. Am Ende eines Messzyklus, wenn Drehmoment und Drehzahl auf null abgesunken sind und folglich die Messung der inneren Messpunkte nicht mehr gestört wird, liegt die Innentemperatur durchschnittlich 6 °C über der Außentemperatur des Rotors.

Außerdem ist zu erkennen, dass die Rotortemperatur sich sehr träge verhält, sowohl beim Aufheizen (s. Abb. 17) wie beim Abkühlen (s. Abb. 18). Dies kann sich positiv auf die Vorhersagegenauigkeit auswirken.




Abbildung 18: Abkühlverhalten Rotor

Die Architektur des RNN zeichnet sich durch seine Fähigkeit aus, zeitliche Abhängigkeiten und sequenzielle Muster in Daten zu erfassen und zu verarbeiten. Diese Eigenschaft erweist sich als besonders vorteilhaft bei der Analyse von Temperaturmessreihen, da die aktuellen Werte maßgeblich von vorherigen Zuständen beeinflusst werden. Die Trägheit dieses Systems begünstigt die Vorhersagegenauigkeit, indem kurzfristige Schwankungen oder Messfehler in ihrer Auswirkung auf die Prognose minimiert werden. In diesem Kontext ist die sorgfältige Auswahl einer adäquaten Länge für das TBPTT Verfahren von entscheidender Bedeutung, um die thermische Trägheit in ausreichendem Maße zu berücksichtigen und somit die Leistungsfähigkeit des Modells zu optimieren.

Ein potenzielles Problem stellt die Bestimmung des Startwertes dar, da keine direkte Zuordnung zwischen einem Zustand (wie Strom, Leistung, Drehmoment oder Drehzahl) und der Temperatur besteht. Es könnte daher vorkommen, dass das RNN bei einem falschen Startwert die Abweichung zur realen Temperatur nicht korrekt oder nur sehr langsam anpasst.

7 Untersuchungen und Optimierung TNN

In diesem Abschnitt wird zunächst das TNN anhand des gegebenen Datensatzes trainiert und auf Grundlage des Validierungsdatsatzes optimiert. Der Trainings- und Validierungsdatsatz besteht aus mehreren Rennzyklen, die bei realen Fahrten auf verschiedenen WRC-Rennstrecken aufgenommen und in jeweils 20-minütige Fahrzyklen unterteilt wurden. Diese Zyklen enthalten Phasen mit hoher und geringer Last sowie Abkühlphasen.

Wie in Kapitel 6 beschrieben, wurden diese Profile am Prüfstand simuliert und die Temperatur mittels Rotortelemetrie aufgezeichnet. Für das Training werden ausschließlich die Temperaturen der Sensoren 1 und 3 verwendet, da mit den Sensoren 2 und 4 keine aussagekräftigen Messungen möglich sind.

Für die initialen Analysen werden folgende Eingabegrößen verwendet: i_d , i_q , $motor_speed$ (Drehzahl), $TStator1$ und $TStator2$ (Statortemperatur) und $TInlet$ Kühlwassertemperatur. Diese Auswahl orientiert sich an den Empfehlungen aus der Veröffentlichung [16]. Darüber hinaus wird untersucht, ob die Integration der in den Grundlagen identifizierten, für die Wärmeverluste relevanten Frequenzen, einen signifikanten Mehrwert bietet. Weitere in der zitierten Veröffentlichung verwendete Größen, wie Drehmoment oder Spannung, werden für das Training nicht berücksichtigt, da sie entweder nur geschätzt oder nicht kontinuierlich gemessen werden können. Sollten diese Daten in Zukunft verfügbar sein, wäre ihre Einbindung in das Training empfehlenswert.

7.1 Optimierung

In diesem Abschnitt wird die Optimierung des TNN hinsichtlich verschiedener Parameter behandelt. Der Fokus liegt dabei auf der Vorverarbeitung des Trainingsdatsatzes, der Anpassung der TBPTT-Länge (Truncated Backpropagation Through Time) sowie der Optimierung der Lernrate. Zusätzlich wird eine Gewichtung der Profile eingeführt, um die durch unterschiedliche Profillängen verursachte implizite Gewichtung auszugleichen. Abschließend werden die Eingabegrößen um die zuvor erwähnten relevanten Frequenzen erweitert.

7.1.1 Trainingsdaten

Anforderungen und Herausforderungen

Das TNN berücksichtigt eine Sample-Time, welche die Zeitdifferenz zwischen zwei aufeinanderfolgenden Zuständen darstellt, also den Diskretisierungsschritt. Der vom Prüfstand erhobene Datensatz wird mit einer Frequenz von 500Hz (entspricht 0,002s) aufgenommen und erzeugt damit für die im Durchschnitt zwanzig minütige Fahrzyklen Datenreihen mit über 600.000 Datenpunkten und in Folge lange Trainingsläufe, sollte man diese Daten unmittelbar nutzen wollen. Zudem schwingen alle Größen, was die Vorhersage verzerren könnte, da der vorherige Zustand nicht zwangsläufig mit dem globalen Trend der jeweiligen Größe in Verbindung gebracht

werden kann, wie auch in der Abbildung 19 zu erkennen ist.

Vorgeschlagene Lösung

Um Ressourcen zu sparen und den globalen Trend der Daten zu berücksichtigen, wird folgendes Vorgehen vorgeschlagen:

1. Aufzeichnung der Daten mit 500 Hz
2. Unterteilung der Daten in Teilstücke der Länge n
3. Berechnung des Mittelwerts für jeden Abschnitt

Dieser Ansatz bewahrt die detaillierte Information über den jeweiligen Zeitraum, reduziert aber gleichzeitig die Größe der Trainingsdatensätze erheblich.




Abbildung 19: Ausschnitt des Drehzahlverlaufs in Blau und in rot die verwendeten Mittelwerte für das Training bei einer Schrittlänge von 500 Datenpunkten oder einer Zeitspanne von einer Sekunde

Bestimmung der zu untersuchenden Paketlängen

Zur Bestimmung einer optimalen Länge für die Zeitschritte wurde die Temperaturveränderung in allen Trainings- und Validierungsprofilen analysiert. Es zeigte sich, dass eine maximale Temperaturänderung über einen Zeitraum von 5 Sekunden $0,5^{\circ}\text{C}$ beträgt, was einer Paketlänge n von 2500 aufeinanderfolgenden Datenpunkten entspricht. Diese Paketlänge ist eine sinnvolle Region für die Optimierung, da, wie aus 20 ersichtlich, Trends immer noch ausreichend erfasst werden.

Untersuchte Paketlängen

Die Tabelle 1 bietet eine Übersicht der analysierten Daten. Sie zeigt die untersuchten Zeitschritte sowie die Anzahl der pro Zeitschritt zusammengeführten Datenpunkte (n). Zusätzlich wird die jeweilige maximale Temperaturänderung (ΔT) angegeben,

die innerhalb des jeweiligen Zeitschritts (Δt) auftritt. Δt stellt die für das Training genutzte Sample-Time dar.

Die Spaltenbezeichnungen P1S1 bis P3S2 stehen für die verschiedenen Kombinationen aus Profilen (1-3) und Sensoren (1-2). Die in diesen Spalten aufgeführten Werte repräsentieren den Mean Squared Error (MSE) für die Vorhersagen des entsprechenden Sensors und Profils. Die Trainingsdauer T_{train} bezieht sich auf die Zeit, die zur Berechnung von 10000 Trainingsepochen benötigt wurde. Für die Auswertung wurde stets das Modell mit dem besten Validation Loss herangezogen.

n	Δt [s]	ΔT [°C]	T_{train}	P1S1	P1S2	P2S1	P2S2	P3S1	P3S2
1	0.002	1	1530h	-	-	-	-	-	-
500	1	0,04	4h	2,068	3,564	12,452	13,803	1,785	2,421
1000	2	0.11	2,5h	0,492	1,309	5,030	9,723	0,449	1,161
2000	4	0,25	1,5h	0,597	0,554	0,666	1,381	0,173	0,351
2500	5	0,5	1,2h	0,641	0,441	0,124	0,329	0,861	0,671
4000	8	1	30min	0,192	0,218	0,893	1,412	0,096	0,078
5000	10	1.6	27min	0,289	0,336	0,889	0,124	0,403	0,333
6000	12	2	23min	0,208	0,331	1,343	0,543	0,438	0,220

Tabelle 1: Untersuchte Zeitschritte

Schlussfolgerung

Bei den höheren Abtastraten sind die Trainingsdaten extrem detailliert. Diese hohe Detailgenauigkeit führt jedoch dazu, dass viele Datenreihen Rauschen und Schwingungen enthalten, die für die Modellvorhersage nicht relevant sind. Dies zeigt sich auch in der Tabelle, wo bei einer Paketlänge von $n = 500$ und $n = 1000$ der mittlere quadratische Fehler (MSE) deutlich größer ist als bei größeren Paketlängen.

Durch die Reduktion der Anzahl der Datenpunkte pro Zeitschritt, also durch die Erhöhung der Paketlänge n , wird die Trainingsdauer erheblich verkürzt und die Vorhersagegenauigkeit gesteigert. Ein klares Optimum geht aus dieser Analyse nicht hervor, da auch die zufällig generierten Initialgewichte einen Einfluss auf den Trainingsverlauf nehmen.




Abbildung 20: Verschiedene Paketlängen und die dadurch abgewandelte Darstellung der Drehzahl im Vergleich

Basierend auf den in der Tabelle dargestellten Ergebnissen erweist sich eine Paketlänge von $n = 2500$ als sinnvoller Kompromiss zwischen Trainingsdauer und Vorhersagegenauigkeit. Diese Paketlänge gewährleistet eine effektive Reduktion der Informationen und des Rauschens, ohne dabei den zugrunde liegenden Trend zu verzerren (s. Abb. 20). Gleichzeitig ermöglicht sie eine signifikante Verkürzung der Trainingsdauer auf 1,2 Stunden und liefert akkurate Vorhersagen.

7.1.2 Analyse der TBPTT-Segmentlänge

Die TBPTT ist eine Technik zur effizienten Optimierung von RNN. Ein kritischer Hyperparameter dieser Methode ist die Segmentlänge, also die Anzahl der Zeitschritte, über die der Gradient zurückpropagiert wird.

Die Wahl der optimalen Segmentlänge stellt einen Kompromiss dar:

- Kürzere Segmente reduzieren den Rechenaufwand und Speicherbedarf.
- Längere Segmente ermöglichen eine bessere Modellierung von langfristigen Abhängigkeiten.

Vergleich der verschiedenen Segmentlängen

Um den Einfluss dieses Parameters zu untersuchen, wurde eine Analyse mit verschiedenen Segmentlängen durchgeführt. Dabei wurden Längen von 16, 32, 64, 128, 256 und 512 Zeitschritten betrachtet. Die Untersuchung basiert auf dem im vorherigen Kapitel 7.1.1 festgelegten Modell mit einem Diskretisierungsschritt von 5 Sekunden.




Abbildung 21: Logarithmisch aufgetragener Validation Loss für verschiedene TBPTT-Segmentlängen.

Die Abbildung 24 zeigt einen klaren Trend. Bei sehr kurzen Segmentlängen ist der Fehler zunächst hoch, da wichtige langreichweitige Abhängigkeiten nicht erfasst werden. Mit zunehmender Segmentlänge sinkt der Fehler rapide ab, bis ein deutliches Minimum bei einer Länge von 128 Zeitschritten erreicht wird. Bei noch längeren Segmenten steigt der Fehler wieder leicht an, was auf Gradienteninstabilität, erhöhtes Rauschen in den Gradienten und eine mögliche Überanpassung an seltene langfristige Abhängigkeiten zurückzuführen sein könnte.

7.1.3 Einbindung von Frequenzgrößen

Um den Einfluss der für Wärmeverluste relevanten Frequenzen auf die Genauigkeit des TNN zu untersuchen, werden zusätzliche Eingabegrößen in das Modell integriert. Basierend auf den theoretischen Grundlagen werden $n^{1.5}$ und n^2 als weitere Eingangsparameter hinzugefügt, wobei n die Drehzahl repräsentiert.

Vorgehen

Zunächst wird das bestehende TNN um die neuen Eingabegrößen $n^{1.5}$ und n^2 erweitert. Anschließend erfolgte ein erneutes Training des Netzwerks mit dem erweiterten Datensatz. Um die Auswirkungen dieser Erweiterung zu evaluieren, werden Vorhersagen des ursprünglichen Modells mit denen des erweiterten Modells verglichen.

Ergebnisse

Die Analyse der Vorhersagegenauigkeit zeigt, dass das um die Frequenzgrößen erweiterte Modell eine minimal schlechtere Performance aufweist. Die beläuft sich im Durchschnitt bei 100 Trainingsdurchläufen je Setup auf 0,003 im MSE. Diese Beobachtung legt nahe, dass der Zusammenhang zwischen Drehzahl und Wärmeverlusten bereits durch die ursprüngliche Eingabegröße der Drehzahl hinreichend abgebildet wurde.

Interpretation

Die leichte Verschlechterung der Modellperformance deutet darauf hin, dass die zusätzlichen Frequenzgrößen keine neuen, für die Vorhersage relevanten Informationen liefern. Stattdessen führt ihre Einbindung zu einer unnötigen Erhöhung der Modellkomplexität. Es ist anzunehmen, dass das NN bereits in der Lage ist, die nichtlinearen Zusammenhänge zwischen Drehzahl und Temperaturentwicklung adäquat zu erfassen.

Schlussfolgerung

Basierend auf diesen Erkenntnissen wurde entschieden, die zusätzlichen Frequenzgrößen $n^{1.5}$ und n^2 nicht in das finale Modell zu integrieren. Diese Entscheidung trägt zur Beibehaltung einer schlanken Modellstruktur bei, ohne die Vorhersagegenauigkeit zu beeinträchtigen. Es unterstreicht zudem die Fähigkeit des ursprünglichen Modells, komplexe Zusammenhänge zwischen den Eingabegrößen und der Temperaturentwicklung effektiv abzubilden.

7.1.4 Optimierung der Lernrate

Die Lernrate ist ein kritischer Hyperparameter im Training von NN, der maßgeblich die Konvergenzgeschwindigkeit und die Qualität des Lernprozesses beeinflusst. In diesem Abschnitt wird die Notwendigkeit einer dynamischen Anpassung der Lernrate nach einer bestimmten Anzahl von Trainingsepochen untersucht und implementiert.

Bei komplexen Optimierungsproblemen, wie sie beim Training von NN auftreten, kann eine konstante Lernrate zu suboptimalen Ergebnissen führen. Zu Beginn des Trainings ist oft eine höhere Lernrate vorteilhaft, um schnell in die Nähe des Optimums zu gelangen. Im weiteren Verlauf kann diese jedoch zu Instabilitäten führen und die Feinabstimmung der Gewichte erschweren. Eine Anpassung der Lernrate nach einer bestimmten Anzahl von Epochen ermöglicht es, diese Herausforderungen zu adressieren und die Konvergenz des Modells zu verbessern.

Beobachtung der Instabilität




Abbildung 22: Logarithmisch aufgetragener Trainings- und Validationloss mit konstanter Lernrate

Das Training wird nach 1800 Epochen zunehmend instabil. Dies äußerte sich in starken Schwankungen des Trainingsloss, wie in Abbildung 22 dargestellt. Der Graph zeigt deutlich, wie der Trainingsverlust nach 1800 Epochen beginnt, stark zu oszillieren. Diese Instabilität deutet darauf hin, dass die initiale Lernrate für die spätere Phase des Trainings zu hoch gewählt ist und das Modell Schwierigkeiten hat, sich dem Optimum weiter anzunähern.

Implementierung der Lernratenanpassung

Um dieses Problem zu adressieren, wird eine dynamische Anpassung der Lernrate implementiert. Nach 1500 Epochen wird die Lernrate um einen Faktor 10 reduziert und bei 5000 erneut um einen Faktor 10. Diese Reduktion ermöglicht es dem Modell, in der späteren Trainingsphase kleinere und präzisere Anpassungen vorzunehmen.

Ergebnisse der Optimierung




Abbildung 23: Logarithmisch aufgetragener Trainings- und Validationloss mit veränderter Lernrate

Die Auswirkungen der Lernratenanpassung sind in Abbildung 23 ersichtlich. Wie der Graph zeigt, führt die Anpassung der Lernrate zu einem deutlich stabileren Trainingsverlauf. Die starken Oszillationen im Trainingsverlust werden reduziert, und das Modell konvergiert gleichmäßiger gegen das Optimum. Dies resultiert nicht nur in einer verbesserten Stabilität des Trainings, sondern auch in einer höheren Genauigkeit des finalen Modells.

Schlussfolgerung

Die dynamische Anpassung der Lernrate hat sich als effektive Methode erwiesen, um die Stabilität und Effizienz des Trainingsprozesses zu verbessern. Diese Optimierung trägt wesentlich zur Verbesserung der Gesamtleistung des TNN bei und unterstreicht die Bedeutung einer sorgfältigen Hyperparameter-Optimierung im Bereich des maschinellen Lernens.

7.2 Untersuchung der Vorhersage

7.2.1 Vorhersage bei exaktem Startwert

In diesem Abschnitt wird die Vorhersagegenauigkeit des TNN für verschiedene Temperaturprofile bei exaktem Startwert untersucht. Die untersuchten Profile unterscheiden sich in ihrer Dauer und ihrem Verlauf. Profil 9 stellt mit einer Dauer von ungefähr 12 Minuten das kürzeste Profil dar, während Profil 7 mit etwa 24 Minuten das längste ist. Bis auf Profil 9, das eine Abkühlung des Systems bei stillstehendem Motor und laufender Kühlung repräsentiert, handelt es sich bei allen anderen Profilen um am Prüfstand simulierte Rennzyklen.

Die Vorhersagen des TNN sind für die meisten Rennzyklen sehr zuverlässig, wie in Abbildung 24 dargestellt. Profil 14 weicht zum Ende hin leicht von der realen Temperatur ab, liefert jedoch insgesamt noch akzeptable Ergebnisse. Eine deutliche Abweichung ist bei der Abkühlkurve (Profil 9) zu erkennen, bei der die Vorhersage nach etwa 12 Minuten eine maximale Abweichung von 13,6 K zeigt. Diese Diskrepanz deutet darauf hin, dass das Modell Schwierigkeiten hat, den Verlauf bei Abkühlung präzise vorherzusagen.




Abbildung 24: Vorhersage des TNN für drei Fahrzyklen und eine Abkühlung von 135°C bis 90°C

7.2.2 Vorhersage bei abweichendem Startwert

Bei RNNs hängt die aktuelle Vorhersage von den vorherigen ab. Dies führt zu der Notwendigkeit, eine initiale Temperatur für den Beginn der Vorhersage festzulegen. In diesem Abschnitt werden verschiedene Methoden zur Bestimmung dieser Initialtemperatur diskutiert und ihre Auswirkungen auf die Genauigkeit der Vorhersage untersucht.

Es gibt mehrere Ansätze, um die Initialtemperatur zu bestimmen. Die Initialtemperatur kann aus der Stator- oder Kühlwassertemperatur abgeschätzt werden, da diese in diesem Projekt gemessen werden. Alternativ kann, wie im späteren Kapitel 8 *EMK Synchronisation* beschrieben, die Initialtemperatur über eine EMK-Messung bestimmt werden. Hierbei wird die Abhängigkeit der EMK von der Temperatur der Permanentmagnete im Rotor genutzt.

Untersuchungen zeigen, dass selbst bei einem fehlerhaften Initialwert eine allmähliche Angleichung der Vorhersage an die tatsächliche Temperatur stattfindet. Dieser Prozess kann jedoch relativ langsam ablaufen, was insbesondere bei kritischen Betriebszuständen problematisch sein kann.




Abbildung 25: Temperaturvorhersage mit einer Starttemperaturabweichung von 45°C. In blau ist die Vorhersage des TNN und in grün die tatsächliche Temperatur dargestellt

Abbildung 25 zeigt den Verlauf der Temperaturvorhersage bei einem ungenauen Initialwert im Vergleich zur tatsächlichen Temperatur. Es wird deutlich, dass es mehrere Minuten dauert, bis sich die Vorhersage der realen Temperatur annähert. Besonders herausfordernd ist der Zustand bei einem Neustart des Fahrzeugs, wenn sich die Temperatur der Vorhersage und die tatsächliche Temperatur so stark unterscheiden, dass eine hohe Drehmomentabweichung vorliegt (s. Abb. 4).

Um die Genauigkeit der Initialtemperatur zu verbessern, können verschiedene Ansätze in Betracht gezogen werden. Falls die Uhrzeit dem Steuergerät bekannt ist, kann die Abkühlkurve des Rotors gespeichert werden, woraus sich dann die neue Starttemperatur berechnen lässt.

In Fällen, in denen die Uhrzeit nicht verfügbar ist, kann die letzte Statortemperatur gespeichert werden. Bei einem Neustart wird anhand der Abkühlcharakteristik des Stators und der aktuell gemessenen Statortemperatur eine Zeitspanne berechnet. Mit dieser Zeitspanne und der Abkühlkurve des Rotors kann dann eine Initialtemperatur bestimmt werden.

Je nach Projektanforderungen und -möglichkeiten muss evaluiert werden, wie die Zeit am effektivsten erfasst oder approximiert werden kann, um die genaueste Initialtemperatur zu erhalten. Dies ist ein kritischer Faktor für die Zuverlässigkeit und Genauigkeit des gesamten Vorhersagemodells. Die genaue Bestimmung der Initialtemperatur ist von entscheidender Bedeutung für die Leistungsfähigkeit des rekurrenten neuronalen Netzwerks, insbesondere in kritischen Betriebszuständen. Die vorgestellten Methoden und Lösungsansätze bieten eine Grundlage für weitere Optimierungen und projektspezifische Anpassungen.

7.2.3 Schlussfolgerung

Die Untersuchung der Vorhersagegenauigkeit bei abweichendem Startwert hat deutlich gezeigt, dass das TNN empfindlich auf die Wahl der initialen Temperatur reagiert. Während das Modell in der Lage ist, sich allmählich an die tatsächliche Temperatur anzupassen, kann dieser Prozess insbesondere bei starker Abweichung zu langsam verlaufen. Diese Verzögerung bei hohen Abweichungen führt wiederum zu einer hohen Drehmomentabweichung und damit zu einem Verlust an Leistung, welcher besonders im Motorsport relevant ist.

Die vorgestellten Ansätze zur Bestimmung des Initialwerts bieten praktikable Lösungen, jedoch bleibt die Herausforderung bestehen, diese Methoden so zu optimieren, dass sie auch bei wechselnden und unvorhersehbaren Betriebsbedingungen zuverlässig sind. Insbesondere bei einem Neustart des Fahrzeugs ist die genaue Bestimmung der Starttemperatur von entscheidender Bedeutung, um eine schnelle und präzise Angleichung der Vorhersage zu gewährleisten.

Angeichts der beschriebenen Herausforderungen ist es unerlässlich, eine Methode zu entwickeln, die eine Temperaturmessung im Betrieb ermöglicht. Eine solche Methode würde nicht nur die Korrektur der Temperaturvorhersage während des Betriebs erlauben, sondern auch eine präzisere Bestimmung des Initialwerts nach einer Standzeit. Die direkte Messung der Rotor- oder Permanentmagnettemperatur könnte somit die Genauigkeit des Vorhersagemodells erheblich verbessern und die Zuverlässigkeit des TNN insgesamt steigern.

Im folgenden Kapitel 8 *EMK Synchronisation* wird eine solche Methode entwickelt, die über die EMK eine Temperaturmessung im Betrieb ermöglichen soll.

8 EMK Synchronisation

8.1 Ansatz

Die Genauigkeit der Temperaturvorhersage für die Permanentmagnete im Elektromotor ist ein relevanter Faktor für die Regelung des Motors. Eine unzureichende Modellierung der Magnettemperatur durch das TNN kann zu Fehleinschätzungen und suboptimalen Regelungen führen. Um diese Herausforderung anzugehen, wird in dieser Arbeit ein Ansatz untersucht, bei dem die Beziehung zwischen der EMK und dem Magnetfluss genutzt wird, um die vorhergesagte Temperatur des TNN während des Betriebs zu korrigieren und damit eine zuverlässigere und akkuratere Temperatur zu bestimmen.

Die Kernidee dieser Methode besteht darin, den versteckten Zustand (Hidden State) des TNN, welcher die geschätzte Temperatur zum vorherigen Zeitpunkt repräsentiert, durch einen Korrekturwert zu ersetzen. Dieser Korrekturwert wird aus der gemessenen EMK abgeleitet, wie in Abbildung 26 dargestellt.




Abbildung 26: Schematische Abbildung des TNN und der rekurrenden Temperatur, welche zu bestimmten Zeitpunkten (Nulldurchgänge des Drehmoments, markiert mit gestrichelten senkrechten Linien) durch eine über die EMK bestimmte Temperatur ersetzt wird.

Diese Methode birgt das Potenzial, die Rotortemperaturvorhersage in folgenden Aspekten zu optimieren:

1. Geringere durchschnittliche Abweichung
2. Ermittlung eines Initialwerts nach Stillstand oder Neustart
3. Gewährleistung erhöhter Zuverlässigkeit durch regelmäßiges Abgleichen

Im Rahmen dieser Untersuchung sind drei zentrale Aspekte zu beleuchten: Zunächst gilt es zu prüfen, ob die bekannte Korrelation zwischen Rotortemperatur und EMK tatsächlich messbar ist, und falls ja, wie präzise die Temperaturbestimmung mittels EMK erfolgen kann. Des Weiteren ist die Häufigkeit möglicher EMK-Korrekturen während eines regulären Renneinsatzes zu analysieren, einschließlich der Identifikation potentieller Zeitfenster für erzwungene EMK-Messungen. Abschließend muss die Realisierbarkeit der drei potentiellen Verbesserungen, basierend auf den gewonnenen Erkenntnissen zur Messbarkeit und Genauigkeit der EMK-Rotortemperatur-Korrelation, geprüft werden.

Darüber hinaus bietet die Korrelation zwischen EMK und Rotortemperatur die Möglichkeit während des Fahrzeugbetriebs zusätzliche Daten zu erfassen. Diese könnten dazu dienen, die Präzision des TNNs unter realen Bedingungen zu verifizieren.

8.2 Messung des EMK-Temperatur-Korrelation

Die Untersuchung des Zusammenhangs zwischen EMK und Rotortemperatur erfordert gezielte Messungen. Dafür wird die EMK erfasst, während gleichzeitig die tatsächliche Rotortemperatur mittels Rotortelemetrie gemessen wird.

Um diesen Zusammenhang präzise zu bestimmen, werden Messungen bei konstanten Drehzahlen durchgeführt. Die EMK wird aufgezeichnet, während sich die Rotortemperatur aufgrund der Verluste erhöht. Dieses Vorgehen ermöglicht es, für jede untersuchte Drehzahl den gesamten EMK-Verlauf über den relevanten Temperaturbereich abzubilden. Es wäre auch möglich, bei konstanter Temperatur mehrere Drehzahlen anzufahren und so ein Gitter an EMK-Messpunkten zu erzeugen. Die Menge an Messpunkten bestimmt schlussendlich wie akkurat die aus EMK und Drehzahl interpolierte Temperatur sein wird.




Abbildung 27: EMK-Messung bei konstanten 12000 U/min

Der Graph in Abbildung 27 zeigt deutlich eine Korrelation zwischen EMK und Rotortemperatur. Diese Aufzeichnung wird für weitere konstante Drehzahlen durchgeführt. Die geringe Signalstörung bietet einen großen Vorteil, da dadurch eine akkurate Zuordnung einer Temperatur zu einer bestimmten Drehzahl-EMK-Kombination möglich ist.

Für diese Arbeit wurde die EMK für die Drehzahlen 6000, 7500, 10000, 11500 und 12000 U/min aufgenommen. Nach Interpolation der aufgezeichneten Kurven erhalten wir das in Abbildung 28 dargestellte Feld. Dieses kann genutzt werden, um aus der während der Fahrt gemessenen EMK und Drehzahl eine Temperatur zu berechnen.




Abbildung 28: EMK-Rotortemperatur-Kennfeld mit Drehzahl Isolinien

Im Hinblick auf die Messung ist zudem zu untersuchen, ob bei Drehzahländerungen eine signifikante Verzögerung in der EMK-Anpassung auftritt. Dazu wird ein Drehzahlanstieg von 3000 U/min auf 5000 U/min im laufenden Betrieb untersucht und beobachtet ob die Einschwingzeit der Drehzahl sich signifikant von der Einschwingzeit der EMK unterscheidet.

Außerdem ist es von entscheidender Bedeutung, die Zeitspanne zu ermitteln, in der das Stellmoment bei Null verbleiben muss, damit eine störungsfreie EMK-Messung durchgeführt werden kann. Um das zu simulieren wird bei konstanter Drehzahl das Drehmoment von 60 Nm auf Null gesetzt.




Abbildung 29: EMK-Einschwingzeit bei Drehzahlwechsel ohne Last

Aus Abbildung 29 wird ersichtlich, dass die Veränderung der EMK und der Drehzahl zeitgleich stattfindet. Dies impliziert, dass keine signifikante Verzögerung der EMK gegenüber der Drehzahländerung auftritt. Folglich können EMK-Messungen auch bei variablen Drehzahlen durchgeführt werden, vorausgesetzt, die fundamentale Bedingung eines annähernd Null-Drehmoments beziehungsweise Stroms ist ausreichend erfüllt.




Abbildung 30: EMK-Einschwingzeit bei Null Stellmoment und konstanter Drehzahl

Abbildung 30 veranschaulicht, dass etwa 1360 ms erforderlich sind, bis sich die EMK stabilisiert hat. Vor diesem Zeitpunkt treten Abweichungen von bis zu 13-V auf. Aufgrund der flachen Charakteristik des Rotortemperatur-EMK-Kennfelds

würden solche Abweichungen zu erheblichen Ungenauigkeiten in der Temperaturberechnung führen. Diese Einschwingzeit ist ein kritischer Faktor bei der Untersuchung der Häufigkeit potentieller Messpunkte während des Betriebs und muss daher sorgfältig berücksichtigt werden.

8.3 Bestimmung der Temperaturgenauigkeit

In diesem Abschnitt wird beschrieben, wie die Temperaturbestimmung aus den Messdaten erfolgt. Außerdem wird die Genauigkeit dieser Methode untersucht.

Die Temperatur wird durch die Erfassung der EMK und der Drehzahl über einen bestimmten Zeitraum ohne Stellmoment berechnet. Die gemessenen Daten werden dann mit Hilfe des EMK-Rotortemperatur-Kennfelds (s. Abb. 28) ausgewertet, um die Temperatur zu bestimmen.

In der Abbildung 31 sind die über einen Zeitraum gemessenen Daten dargestellt. Der Graph zeigt die Rotortemperatur, das Drehmoment, die EMK, die Drehzahl und den Strom. Aus diesen Daten wird die durchschnittliche EMK und die durchschnittliche Drehzahl berechnet. Das Drehmoment in Abbildung 31 ist ungleich Null, da es sich hierbei um das gemessene Moment handelt und geringe Schleppverluste immer vorliegen.




Abbildung 31: Verlauf der gemessenen Größen über die Zeit bei ausreichend langem Null-Stellmoment

Die Bestimmung der Temperatur erfolgt durch die in Abbildung 32 dargestellten Schritte. Schritt 1 und 2 werden in der Abbildung 31 und Schritt 3 in Abbildung 33 dargestellt:




Abbildung 32: Vorgehen zu Berechnung der Rotortemperatur aus der EMK

In der dargestellten Messreihe beträgt die durchschnittliche EMK 273,37 V und die durchschnittliche Drehzahl 8799,49 U/min. Diese Werte werden in das Kennfeld eingetragen (gekennzeichnet durch die roten und blauen Linien in Abbildung 33), um die Rotortemperatur zu bestimmen. Die interpolierte Temperatur beträgt hierbei 62,48°C und weicht damit um 5,28°C von der tatsächlichen Temperatur ab.




Abbildung 33: Interpolation der Rotortemperatur aus dem EMK-Rotortemperatur-Kennfeld

Weitere Temperaturberechnungen aus Messungen zeigen Abweichungen im Bereich von 2 bis 10°C auf. Die Präzision der Bestimmung wird maßgeblich von zwei Faktoren beeinflusst. Zum einen spielt die Dichte der Messpunkte im Kennfeld eine entscheidende Rolle: Eine höhere Anzahl an Messpunkten ermöglicht eine feinere Interpolation und führt somit zu einer exakteren Temperaturbestimmung. Zum anderen ist die Zeitspanne, in der das Stellmoment bei Null verharret, von Bedeutung. Je länger diese Phase andauert, desto genauer kann die Temperatur erfasst werden. Diese beiden Aspekte tragen wesentlich zur Gesamtgenauigkeit der Temperaturmessung bei und müssen bei der Anwendung sorgfältig berücksichtigt werden.

8.4 Möglichkeiten zur EMK-Messung im Fahrbetrieb

In diesem Abschnitt wird untersucht, ob es möglich ist, während des laufenden Betriebs eine EMK-Messung ohne künstlich erzwungenes Null-Stellmoment durchzuführen. Ein spezifisches Fahrprofil zeigt, dass es im laufenden Betrieb durchaus Zeitpunkte gibt, an denen dies möglich ist. Es ist jedoch wichtig zu beachten, dass dieses Fahrprofil nur für eine bestimmte Rennserie repräsentativ ist und andere Projekte möglicherweise weniger Gelegenheiten für solche Messungen bieten.




Abbildung 34: Verlauf eines bei der Fahrt aufgenommenen Stellmoments und Zeitpunkte mit mindestens 2 Sekunden bei Null-Moment

Der Graph in Abbildung 34 zeigt, dass es während des regulären Fahrbetriebs in dieser spezifischen Aufzeichnung eines WRC Fahrzeuges 18 Zeiträume gibt, in denen das Stellmoment von selbst auf Null abfällt und eine EMK-Messung ohne Eingriff möglich wäre. Diese Zeitspannen sind lang genug, um eine eingeschwungene Quellspannung zu messen.

Es ist jedoch wichtig zu betonen, dass diese Häufigkeit von Messmöglichkeiten nicht für alle Rennserien gilt. Erfahrungsgemäß gibt es in anderen Rennserien deutlich seltener bis kaum Gelegenheiten für solche Messungen. Daher muss auch die Möglichkeit in Betracht gezogen werden, EMK-Messungen gezielt herbeizuführen.

In Szenarien mit weniger natürlichen Messgelegenheiten könnten bestimmte Situationen genutzt werden, um das Stellmoment gezielt auf Null zu setzen und eine EMK-Messung zu ermöglichen. Solche Situationen könnten beispielsweise sein:

- Beim Pit Entry im Motorsport, wo das Fahrzeug ohnehin langsamer wird.
- Während längerer Bremsphasen oder bei geringen Geschwindigkeiten auf Geradenabschnitten.
- Während einer Safety-Car-Phase, in der das Fahrzeugtempo stark reduziert ist.
- Während eines Boxenstopps, wenn das Fahrzeug zum Stillstand kommt.
- Während längerer Kurvenfahrten, bei denen das Drehmoment typischerweise niedriger ist.
- Beim Hochlauf nach einem Stillstand oder beim Erststart des Fahrzeugs.

Insbesondere die Bestimmung der initialen Temperatur nach einem Stillstand oder beim Erststart des Fahrzeugs kann von dieser Methode erheblich profitieren. Diese initiale Temperatur ist entscheidend für die Genauigkeit der Temperaturvorhersagen des TNNs, wie im Kapitel 7.2.2 *Vorhersage bei abweichendem Startwert* ausführlich erläutert wird.

Die Wahl der Messstrategie - ob natürliche Messgelegenheiten genutzt oder künstlich herbeigeführt werden - hängt stark von den spezifischen Anforderungen und Bedingungen der jeweiligen Projekts ab. In jedem Fall ist es wichtig, einen Kompromiss zwischen der Häufigkeit der Messungen und der Minimierung von Eingriffen in den Rennverlauf zu finden.

8.5 Schlussfolgerung

Die in diesem Kapitel vorgestellte Methode zur Bestimmung der Rotortemperatur anhand der EMK hat gezeigt, dass sie ausreichend genaue Temperaturwerte liefern kann. Diese Genauigkeit wird vor allem durch die sorgfältige Erfassung und Analyse der EMK-Daten erreicht, die es ermöglichen, die Temperatur durch Interpolation des EMK-Rotortemperatur-Kennfelds präzise zu berechnen.

Ein wesentlicher Vorteil dieser Methode ist, dass sie keinen zusätzlichen Aufwand neben dem TNN erfordert. Die einzige Voraussetzung für die Implementierung ist der Einbau einer Rotortemperaturmessung, welche für das Training des TNN ohnehin notwendig ist.

Die Untersuchung hat gezeigt, dass die Häufigkeit der Messmöglichkeiten stark von der spezifischen Rennserie abhängt. In der analysierten Serie wurden 18 Zeiträume identifiziert, in denen eine natürliche EMK-Messung möglich ist.. Es ist jedoch wichtig zu betonen, dass diese Häufigkeit nicht für alle Rennserien gilt. In vielen Fällen gibt es deutlich weniger natürliche Gelegenheiten für solche Messungen.

Trotz der potenziell begrenzten Messgelegenheiten in manchen Rennserien bleibt die EMK-basierte Temperaturbestimmung eine wertvolle Methode, insbesondere für die Bestimmung des Initialwerts beim Erststart oder nach Standphasen. In solchen Situationen kann eine einmalige, gezielte Messung zu Beginn des Betriebs durchgeführt werden, um das TNN mit einer genauen Anfangstemperatur zu versorgen. Dies stellt sicher, dass die Vorhersagen des TNN von Anfang an präzise sind und die Motorregelung optimal unterstützt wird.

Für Rennserien mit weniger natürlichen Messmöglichkeiten muss projektspezifisch bewertet werden, wann eine erzwungene Messung durchführbar ist. Szenarien wie Pit Entries, Safety-Car-Phasen oder Boxenstopps bieten potenzielle Gelegenheiten, in denen das Stellmoment auf Null gesetzt werden kann, um eine EMK-Messung durchzuführen, ohne den Rennverlauf wesentlich zu beeinträchtigen.

Zusammenfassend lässt sich sagen, dass die EMK-basierte Temperaturbestimmung eine wertvolle Ergänzung zur bestehenden Temperaturmodellierung darstellt. Ihre Anwendbarkeit zur kontinuierlichen Verbesserung der TNN-Vorhersagen hängt stark von der spezifischen Rennserie ab. In jedem Fall bietet sie eine effektive Methode zur Bestimmung des Initialwerts und trägt somit zur Genauigkeit und Zuverlässigkeit der Motorregelung bei. Jede Implementierung sollte projektspezifisch angepasst werden, um die optimalen Zeitpunkte für Messungen zu identifizieren – sei es durch Nutzung natürlicher Gelegenheiten oder durch gezielte Herbeiführung – und so die Vorteile dieser Methode voll auszuschöpfen.

9 Implementierung auf das Steuergerät

9.1 Möglichkeiten der Implementierung

Für den WRC Motor wird die Regelung als Blockschaltbild in Simulink definiert, anschließend als C-Code exportiert und über eine zweite Software in hex-Code umgewandelt wird, welcher dann wiederum auf das Steuergerät geflashed werden kann. Somit ist die Implementierung des TNN in Simulink das Ziel. Um das zu erreichen, gibt es mehrere Möglichkeiten, auf die der Vollständigkeit halber kurz eingegangen wird:

- Matlab Funktion: **importONNXFunction**
- Matlab Funktion: **importNetworkFromPyTorch**
- Das Netzwerk in Matlab definieren und trainieren
- Den Forward Pass als Funktion definieren und die Weights and Biases importieren

Der Import neuronaler Netzwerkstrukturen mithilfe der vorhandenen Matlab-Funktionen gestaltet sich aufgrund zahlreicher Fehlermeldungen schwierig, insbesondere bei rekurrenten Architekturen. Diese Optionen erweisen sich daher als ungeeignet. Eine vollständige Modellierung und das Training des Netzwerks in Matlab wären zwar möglich, jedoch zeitaufwendig. Zudem bietet die Deep Learning Toolbox von Matlab im Vergleich zu PyTorch oder TensorFlow weniger Optionen, weshalb eine langfristige Entwicklung in dieser Software kontraproduktiv erscheint. PyTorch als Open-Source-Lösung stellt hier eine vielversprechende Alternative dar.

Die Implementierung des Forward-Passes als Funktion sowie die Modellierung der rekurrenten Verbindungen als Blockschaltbild lassen sich in Matlab unkompliziert umsetzen, da es sich im Wesentlichen um einfache Tensorberechnungen handelt, die in Matlab ohne Weiteres realisiert werden können.

Darüber hinaus ist das in dieser Arbeit verwendete TNN ein sehr kompaktes NN mit wenigen Funktionen und kleinen Gewichtstensoren, die nur wenig Speicherplatz beanspruchen. Im folgenden Kapitel wird die Implementierung dieses TNN detailliert erläutert.

9.2 TNN als Blockschaltbild

Das Blockschaltbild des TNN gliedert sich in drei Ebenen. Die erste Ebene (s. Abb. 35) umfasst den Import aller erforderlichen Größen sowie die Berechnung des Rotortemperatur-Mittelwerts, welcher für die Regelung genutzt wird. Die zweite, tiefer liegende Ebene (s. Abb. 36) beinhaltet die Berechnung des Anfangswerts, die Eingabe der Größen in die Input-Layer des TNN sowie die Ausgabe der vorhergesagten Werte. Die dritte Ebene, welche den Forward-Pass beinhaltet, ist mit einer gestrichelten roten Linie (s. Abb. 36) und der Nummer 5 in dem Blockschaltbild umrandet und beinhaltet den zugehörigen Matlab-Code. Zusätzlich wird ein sogenanntes Chart verwendet (s. Abb. 37), um zwischen drei Zuständen zu wechseln: einem Zustand, in dem Daten gesammelt und gemittelt werden, einem anderen, in dem die Vorhersage mit diesen Daten durchgeführt wird und einem letztem in dem die Speicher geleert werden. Diese drei Zustände werden in einer ausgewählten Taktung zyklisch durchlaufen, dieser Takt ergibt sich aus der Optimierung in Kapitel 7.1.1.

In der Abbildung 35 ist die erste Ebene dargestellt. Der mit *Eingabegrößen* markierte Bereich repräsentiert alle Größen, die im weiteren Verlauf des Prozesses genutzt werden. Diese Größen müssen angepasst werden, wenn sich die Eingangsgrößen für das TNN oder umliegende Berechnungen ändern.

Der mit *TNN* bezeichnete Block beinhaltet die Berechnung der Startwerte und die Normierung der Größen und die Vorhersage selbst. Im grün umrandeten Bereich *Ausgabe für die Regelung* wird die Rotortemperatur einerseits an den Bus weitergegeben um die Daten aufzuzeichnen. Gleichzeitig wird die gemittelte Rotortemperatur für die weitere Verarbeitung in der Steuerung bereitgestellt.




Abbildung 35: Blockschaltbild erste Ebene

In dem in Abbildung 35 mit *TNN* beschrifteten System befindet sich das in Abbildung 36 dargestellte Schaltbild. In dem Kasten 1 werden die Eingabegrößen empfangen und über einen Integrator summiert. Dieser Integrator wird dann wieder zurückgesetzt, sobald das Chart im Kasten 4 ein Signal absendet, also direkt nach einer Vorhersage. Der folgende Kasten 2 berechnet den durchschnitt der in Kasten 1 summierten Daten. In dem Kasten 5 befindet sich der Forward Pass des TNN und es wird mit den Daten aus Kasten 2 und 3 eine Vorhersage getätigt sobald das chart ein Signal absendet. Kasten 3 beinhaltet einerseits die Startwerte der Rotortemperatur, die hier noch durch eine Konstante festgelegt sind und die rekurrende verbindung, weklche die Vorhersage des TNN wieder als Eingabe verwendet. Ein Verzögerungsglied hier stellt sicher, dass die Daten zum richtigen Zeitpunkt den Block erreicht.




Abbildung 36: Blockschaltbild zweite Ebene




Abbildung 37: Chart im Simulink Modell mit den drei Zuständen, die sich aus der Kombination von Predict (Vorhersage des TNN) und Reset (Summe der Eingabedaten zurücksetzen) zusammensetzen

Die einzelnen Größen in diesem Blockschaltbild können sich durch Optimierungsprozesse verändern. Insbesondere die Bestimmung der Starttemperatur muss im speziellen Anwendungsfall definiert werden. Grundsätzlich bietet diese modulare Architektur die Möglichkeit, das TNN oder andere RNN in ein Simulink-Modell zu integrieren. Zuletzt wird eine Vorhersage mit diesem Modell und idealem Startwert durchgeführt um die funktionsfähigkeit zu überprüfen (s. Abb. 38). Es wird deutlich, dass die Implementierung des TNN auf dem Steuergerät erfolgreich ist.




Abbildung 38: Vorhersage eines Rotortemperaturverlaufs über das Simulink-Modell in rot, die reale Temperatur in grün. Die x-Achse stellt die Zeit in Sekunden und die y-Achse die Temperatur in °C dar.

10 Zusammenfassung und Ausblick

10.1 Zusammenfassung der Ergebnisse

Die Rotortemperatur spielt eine entscheidende Rolle für die Leistungsfähigkeit und Zuverlässigkeit eines Elektromotors. Sie beeinflusst direkt die Stärke des Magnetfelds und damit das erzeugte Drehmoment. Eine Erhöhung der Rotortemperatur kann zu einer Schwächung des Magnetfelds führen, was die Präzision des Drehmoments beeinträchtigt. In anspruchsvollen Anwendungen wie dem Motorsport, wo Genauigkeit und Leistung ausschlaggebend sind, können bereits geringfügige Abweichungen des Drehmoments über Erfolg oder Misserfolg entscheiden. Eine präzise Überwachung der Rotortemperatur ermöglicht es, den Motor optimal zu betreiben und das Risiko von Leistungseinbußen oder Ausfällen zu minimieren. Vor diesem Hintergrund wurde die Implementierung eines TNN sowie dessen praktische Umsetzbarkeit untersucht.

Das TNN erweist sich als vielversprechender Ansatz zur Bestimmung der Rotortemperatur während des Betriebs, mit Temperaturvorhersagen, die um 2-3°C vom tatsächlichen Wert abweichen. Diese Genauigkeit ist für die zuverlässige Steuerung des Elektromotors von großer Bedeutung. Allerdings hängt die Präzision der Vorhersagen maßgeblich von einem exakten Startwert der Rotortemperatur ab. Ein ungenauer Ausgangswert führt zu einer langen Anpassungszeit zwischen vorhergesagter und realer Temperatur, daher ist die Bestimmung des Startwertes für das TNN von entscheidender Bedeutung, um die Verlässlichkeit der Temperaturvorhersagen zu gewährleisten.

Die hieraus abgeleitete Methode, die Rotortemperatur über die EMK zu ermitteln, stellt einen zuverlässigen Ansatz dar, um den Startwert für das TNN zu bestimmen. Durch die Korrelation zwischen EMK und Rotortemperatur kann diese Methode sicherstellen, dass das TNN mit einem präzisen Ausgangswert initialisiert oder zwischenzeitlich kalibriert wird. Die Herausforderung liegt hierbei in der Erfüllung der für die Messung erforderlichen Randbedingungen. Um diesem Problem zu begegnen, wurden spezifische Zeitpunkte, wie beispielsweise der Pit-Entry, vorgeschlagen, um eine EMK-Messung zu ermöglichen.

Zuletzt hat die erfolgreiche Implementierung des TNN auf dem Steuergerät dessen Praxistauglichkeit unter Beweis gestellt. Zusammenfassend lässt sich festhalten, dass das in Kapitel 5 vorgestellte Vorgehen einen durchdachten und strukturierten Arbeitsablauf darstellt, um die Anwendung des TNN für einen permanenterregten Synchronmotor (PMSM) erfolgreich zu realisieren.

10.2 Ausblick

Die erfolgreiche Implementierung und Anwendung des TNN zur Vorhersage der Rotortemperaturen in einem PMSM eröffnet ein breites Spektrum an weiteren Anwendungsmöglichkeiten. Das Konzept, Sensoren durch NN zu ersetzen, bietet insbesondere in Situationen, in denen der Einbau von Sensoren außerhalb des Prüfstands schwierig oder unmöglich ist, eine vielversprechende Alternative.

Das TNN könnte in verschiedenen Bereichen der Elektromobilität und darüber hinaus eingesetzt werden. Im Bereich des Batteriemanagements könnte es zur Vorhersage von Batterietemperaturen dienen oder in der Leistungselektronik könnte das TNN für die Temperaturvorhersage in Wechselrichtern und anderen leistungselektronischen Komponenten eingesetzt werden.

Trotz der vielversprechenden Ergebnisse bleiben Herausforderungen bestehen, die in zukünftigen Forschungsarbeiten adressiert werden sollten. Ein wichtiger Aspekt ist die Generalisierbarkeit, damit das TNN auf verschiedene Motoren und verschiedene Umgebungsbedingungen übertragbar wird. Eine solche Übertragbarkeit würde den Einsatzbereich des TNN erheblich erweitern und könnte zu einer signifikanten Reduzierung von Entwicklungszeit und -kosten führen, da nicht für jeden Motortyp oder jede Betriebsumgebung ein spezifisches Modell trainiert werden müsste.

Die Bestimmung einer Initialtemperatur für die erste Vorhersage des TNN wird weiterhin ein relevantes Thema sein und weitere Ansätze müssen hier je nach Anwendungsfall untersucht werden.

Zusammenfassend lässt sich sagen, dass der Einsatz von NN als Sensorersatz, wie am Beispiel des TNN demonstriert, ein vielversprechender Ansatz ist, um technische Herausforderungen in verschiedenen Anwendungsbereichen zu bewältigen. Die Weiterentwicklung und breitere Anwendung dieser Methode könnte zu signifikanten Fortschritten in der Effizienz, Zuverlässigkeit und Leistungsfähigkeit elektrischer Systeme führen.

Literatur

- [1] *Numpy v1.26.4*. <https://numpy.org/>.
- [2] *Pandas v2.1.4*. <https://pandas.pydata.org/docs/index.html>.
- [3] *Pytorch v2.2.2*. <https://pytorch.org/>.
- [4] *Scipy v1.11.4*. <https://www.scipy.org/>.
- [5] *Tensorflow*. <https://tensorflow.org/>.
- [6] A. BINDER, *Elektrische Maschinen und Antriebe*, Springer Vieweg Berlin, Heidelberg, 2 ed., 2018.
- [7] EBM-PAPST, *Außenläufer*. https://mag.ebmpapst.com/de/produkte/ventilatoren/aussenlaeufer-brauchen-keine-seltene-erden-magnete_8969/, 2024. Zugriff am: 22.08.2024.
- [8] FÉDÉRATION INTERNATIONALE DE L'AUTOMOBILE, *2024 WRC Sporting Regulations*. <https://www.fia.com/regulation/category/119>, 2024. Zugriff am 15.05.2024.
- [9] M. GANCHEV, B. KUBICEK, AND H. KAPPELER, *Rotor temperature monitoring system*, in The XIX International Conference on Electrical Machines - ICEM 2010, 2010, pp. 1–5.
- [10] GENERALDIREKTION KOMMUNIKATION, EUROPÄISCHES PARLAMENT, *Eu-verkaufsverbot für neue benzin- und dieselfahrzeuge ab 2035 – was bedeutet das?*, (2022). Veröffentlicht: 03-11-2022, Letzte Aktualisierung: 03-07-2023, Artikelnummer: 20221019STO44572.
- [11] HENKEL ADHESIVES, *Loctite ea 9497*. https://www.henkel-adhesives.com/de/de/produkt/structural-adhesives/loctite_ea_9497.html, 2024. Zugriff am: 11.06.2024.
- [12] S. HÖNICKE, K.-F. WITTEW, AND J. LIEBOLD, *Back-to-back-prüfung von elektromotoren*, MTZextra, 27 (2022), pp. 18–23.
- [13] H. JAEGER, *Tutorial on training recurrent neural networks, covering BPPT, RTRL, EKF and the “echo state network” approach*, GMD Forschungszentrum Informationstechnik, 2002.
- [14] L. JIN, Y. MAO, X. WANG, L. LU, AND Z. WANG, *A model-based and data-driven integrated temperature estimation method for pmsm*, IEEE Transactions on Power Electronics, 39 (2024), pp. 8553–8561.
- [15] T. D. KEFALAS AND A. G. KLADAS, *Finite element transient thermal analysis of pmsm for aerospace applications*, in 2012 XXth International Conference on Electrical Machines, 2012, pp. 2566–2572.

- [16] W. KIRCHGÄSSNER, O. WALLSCHEID, AND J. BÖCKER, *Thermal neural networks: Lumped-parameter thermal modeling with state-space machine learning*, Engineering Applications of Artificial Intelligence, 117 (2023), p. 105537.
- [17] S. LIU, E. HOFFMAN, AND J. BROWN, *Long-term aging of sm/sub 2/(co,fe,cu,zr)/sub 17/ permanent magnets at 300 and 400/spl deg/c*, IEEE Transactions on Magnetism, 33 (1997), pp. 3859–3861.
- [18] MATHWORKS, *Simulink 2017a*, MathWorks, 2017. Version 2017a.
- [19] H. NGUYEN-SCHÄFER, *Grundlagen von Wälzlager*, Springer Berlin Heidelberg, Berlin, Heidelberg, 2017, pp. 183–197.
- [20] S. OECHSLEN, *Thermische Modellierung elektrischer Hochleistungsantriebe*, Wissenschaftliche Reihe Fahrzeugtechnik Universität Stuttgart, Springer Vieweg Wiesbaden, 1 ed., 2018.
- [21] PAUL KEITH, *New engines, rallies and a sprint format: WRC is a must-watch in 2024*. /<https://www.redbull.com/in-en/what-is-wrc-guide>.
- [22] D. D. REIGOSA, D. FERNANDEZ, T. TANIMOTO, T. KATO, AND F. BRIZ, *Permanent-magnet temperature distribution estimation in permanent-magnet synchronous machines using back electromotive force harmonics*, IEEE Transactions on Industry Applications, 52 (2016), pp. 3093–3103.
- [23] J. RICHTER, *Modellbildung, Parameteridentifikation und Regelung hoch ausgenutzter Synchronmaschinen*, PhD thesis, Karlsruher Institut für Technologie (KIT), 2016.
- [24] S. RICHTER, *Supervised Learning: Grundlagen*, Springer Berlin Heidelberg, Berlin, Heidelberg, 2019, pp. 1–24.
- [25] N. ROSTAMI, M. R. FEYZI, J. PYRHONEN, A. PARVIAINEN, AND M. NIEMELA, *Lumped-parameter thermal model for axial flux permanent magnet machines*, IEEE Transactions on Magnetism, 49 (2013), pp. 1178–1184.
- [26] J. SAARI, *Thermal analysis of high-speed induction machines*, 1998.
- [27] H. SCHREMSEER AND H. BAUSCH, *Elektromagnetische Wechselwirkungen*, Vieweg+Teubner Verlag, Wiesbaden, 1998, pp. 165–166.
- [28] R. C. STAUEMEYER AND E. R. MORRIS, *Understanding lstm – a tutorial into long short-term memory recurrent neural networks*, 2019.
- [29] O. WALLSCHEID AND J. BÖCKER, *Global identification of a low-order lumped-parameter thermal network for permanent magnet synchronous motors*, IEEE Transactions on Energy Conversion, 31 (2016), pp. 354–365.
- [30] A. A. WAOO AND B. K. SONI, *Performance analysis of sigmoid and relu activation functions in deep neural network*, in Intelligent Systems, A. Sheth, A. Sinhal, A. Shrivastava, and A. K. Pandey, eds., Singapore, 2021, Springer Singapore, pp. 39–52.

Liste der Abbildungen

1	Exemplarischer Aufbau eines Außenläufers [7]	6
2	Übersicht eines Spannungszeigers in den verschiedenen Koordinatensystemen [23]	7
3	Transformierte Größen: Zunächst der dreiphasige Strom der über die Park-Transformation in den zweiten Graph und über die Clark-Transformation in den dritten Graph umgewandelt wird.	8
4	Drehmomentabweichung über die Statortemperatur	9
5	Beispiel Neuron mit einer Sigmoid-Aktivierungsfunktion [28]	14
6	Sigmoid- und Tanh-Funktion [30]	16
7	Schema eines RNN	18
8	Schematischer Aufbau des TNN [16]	25
9	Schematischer Ablauf der Arbeitsschritte um die Temperaturgröße in der Regelung des WRC-Motors durch ein TNN zu bestimmen	27
10	Prüfstand in Back-to-Back Anordnung mit angebunden Messinstrumenten und Stromversorgung	29
11	Nahaufnahme des Motors mit integrierter Rotortelemetrie	30
12	Schematische Schnittansicht der Messpunkte im Rotor. Zu sehen ist der Rotor rechts geschnitten normal zur Rotationsachse des Motors und links senkrecht dazu.	31
13	Rotor mit eingeschliffener Nut für die Messspitze auf der Innenseite der Magnete in rot umrahmt	32
14	Nahaufnahme der Nut	32
15	Eingeklebtes Thermoelement mit gelb-grüner Verkablung	33
16	Blick auf den Rotor von der anderen Seite: Die hellblauen Pfeile am Rand zeigen die Position der Bohrung für die Messposition am Außendurchmesser der Magnete an	33
17	Temperaturmessung der vier Thermoelemente während eines simulierten Fahrzyklus	35
18	Abkühlverhalten Rotor	36
19	Auschnitt des Drehzahlverlaufs in Blau und in rot die verwendeten Mittelwerte für das Training bei einer Schrittlänge von 500 Datenpunkten oder einer Zeitspanne von einer Sekunde	38
20	Verschiedene Paketlängen und die dadurch abgewandelte Darstellung der Drehzahl im Vergleich	40
21	Logarithmisch aufgetragener Validation Loss für verschiedene TBPTT-Segmentlängen.	41
22	Logarithmisch aufgetragener Trainings- und Validationloss mit konstanter Lernrate	43
23	Logarithmisch aufgetragener Trainings- und Validationloss mit veränderter Lernrate	44
24	Vorhersage des TNN für drei Fahrzyklen und eine Abkühlung von 135°C bis 90°C	45

25	Temperaturvorhersage mit einer Starttemperaturabweichung von 45°C. In blau ist die Vorhersage des TNN und in grün die tatsächliche Temperatur dargestellt	46
26	Schematische Abbildung des TNN und der rekurrierenden Temperatur, welche zu bestimmten Zeitpunkten (Nulldurchgänge des Drehmoments, markiert mit gestrichelten senkrechten Linien) durch eine über die EMK bestimmte Temperatur ersetzt wird.	48
27	EMK-Messung bei konstanten 12000 U/min	49
28	EMK-Rotortemperatur-Kennfeld mit Drehzahl Isolinien	50
29	EMK-Einschwingzeit bei Drehzahlwechsel ohne Last	51
30	EMK-Einschwingzeit bei Null Stellmoment und konstanter Drehzahl	51
31	Verlauf der gemessenen Größen über die Zeit bei ausreichend langem Null-Stellmoment	52
32	Vorgehen zu Berechnung der Rotortemperatur aus der EMK	53
33	Interpolation der Rotortemperatur aus dem EMK-Rotortemperatur-Kennfeld	53
34	Verlauf eines bei der Fahrt aufgenommenen Stellmoments und Zeitpunkte mit mindestens 2 Sekunden bei Null-Moment	54
35	Blockschaltbild erste Ebene	58
36	Blockschaltbild zweite Ebene	59
37	Chart im Simulink Modell mit den drei Zuständen, die sich aus der Kombination von Predict (Vorhersage des TNN) und Reset (Summe der Eingabedaten zurücksetzen) zusammensetzen	60
38	Vorhersage eines Rotortemperaturverlaufs über das Simulink-Modell in rot, die reale Temperatur in grün. Die x-Achse stellt die Zeit in Sekunden und die y-Achse die Temperatur in °C dar.	60